



PROPOSAL SKRIPSI

Judul:

Implementasi Intelligent K-Means dan RAG untuk
Pengembangan Sistem Perencanaan Perjalanan Wisata
Berdasarkan
Semantik dan Spasial

Disusun oleh:

NICO THOMAS
NIM. 535220133

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TARUMANAGARA
2026

Persetujuan

Nama : NICO THOMAS
NIM : 535220133
Program Studi : TEKNIK INFORMATIKA
Judul : Implementasi Intelligent K-Means dan RAG untuk
Pengembangan Sistem Perencanaan Perjalanan Wisata
Berbasis Semantik dan Spasial

Proposal Skripsi ini disetujui untuk diuji

Jakarta, 26-Februari-2026

Pembimbing:
TRI SUTRISNO, S.Si., M.Sc.
NIK/NIP: 10816004



Pembimbing Pendamping:
NOVARIO JAYA PERDANA, S.Kom., M.T.
NIK/NIP: 10817002



Digitally signed by
Novario Jaya
Perdana
Date: 2026-03-02
10:08+07:00

ABSTRAK

Nico Thomas, NPM: 535220133. Implementasi Intelligent K-Means dan RAG untuk Pengembangan Sistem Perencanaan Perjalanan Wisata Berbasis Semantik dan Spasial. Skripsi, Jakarta: Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara, Februari 2026

Perencanaan perjalanan wisata merupakan tantangan berat yang perlu dihadapi para wisatawan karena dalam melakukan pemilihan destinasi selalu melibatkan banyak pertimbangan baik preferensi, efisiensi jarak, aksesibilitas transportasi umum, serta ketersediaan fasilitas pendukung di sekitar destinasi. Kondisi mobilitas wisata yang tinggi, tetapi beberapa kunjungan durasi yang relatif singkat menuntut adanya sistem perencanaan yang terstruktur dan personal agar meningkatkan minat wisatawan dalam berkunjung di suatu tempat. Penelitian ini dilakukan dengan tujuan untuk merancang dan mengimplementasikan sistem perencanaan perjalanan wisata berbasis *web* yang menggabungkan pemahaman semantik preferensi pengguna dan analisis spasial untuk menghasilkan rekomendasi destinasi yang telah dikelompokkan berdasarkan karakteristik, sehingga wisatawan dapat memilih destinasi wisata yang personal dan terstruktur. Pada penelitian ini, sistem yang dibuat mengintegrasikan data spasial destinasi (POI) dari OpenStreetMap, data transportasi umum dari GTFS (halte stop), serta data deskriptif destinasi yang didapat dari buku panduan wisata yang diekstraksi dan dicocokkan menggunakan *fuzzy matching* serta geocoding untuk entitas yang tidak ditemukan. Preferensi pengguna diproses dengan pendekatan *Retrieval-Augmented Generation* (RAG) melalui *embedding* (model *nomic-embed-text*) dan pencarian kemiripan semantik (cosine similarity) untuk menghasilkan skor relevansi destinasi. Skor relevansi ini digabungkan dengan fitur geospasial dan konteks perjalanan (koordinat, jarak ke hotel, jarak ke halte terdekat, frekuensi layanan, serta jumlah fasilitas pendukung seperti restoran dan minimarket dalam radius yang ditetapkan), kemudian dinormalisasi dan dikelompokkan menggunakan algoritma Intelligent K-Means dengan pemilihan jumlah *cluster* berbasis Silhouette Score dan WCSS. Pengguna memilih destinasi dalam *cluster* yang telah diinterpretasikan (contoh kelompok destinasi yang dekat hotel dan restoran yang melimpah). Destinasi-destinasi yang dipilih akan dioptimasi reutenya menggunakan algoritma Greedy Nearest Neighbor berbasis jarak Haversine. Rancangan ini menyediakan kerangka kerja hibrida yang mengintegrasikan RAG untuk personalisasi semantik dan Intelligent K-Means untuk pengelompokan destinasi berbasis spasial-kontekstual, sehingga mendukung penyusunan itinerary yang lebih personal, efisien, dan terukur.

Kata Kunci: Semantik, Spasial, Intelligent K-Means, Clustering Destinasi Wisata, Optimasi Route

KATA PENGANTAR

Segala puji dan syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat, rahmay, dan karunia-Nya, sehingga penulis dapat menyelesaikan penyusunan skripsi yang berjudul "Implementasi Intelligent K-Means dan RAG untuk Pengembangan Sistem Perencanaan Perjalanan Wisata Berbasis Semantik dan Spasial" dengan baik dan tepat waktu.

Penyusunan skripsi ini dilakukan untuk memanuhi salah satu persyaratan akademik yang wajib ditempuh untuk memperoleh gelar Sarjana pada Program Studi Teknik Informatika, Fakultas Teknologi Informasi, Universitas Tarumanagara.

Dalam proses penyusunan skripsi ini, penulis tidak akan dapat menyelesaikan skripsi ini tanpa bantuan, dukungan, bimbingan, serta motivasi dari pihak yang terlibat baik secara langsung maupun tidak langsung. Pada kesempatan ini, penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada:

1. Ibu Prof. Dr. Ir. Dyah Erny Herwindiati, M.Si. Selaku Dekan Fakultas Teknologi Informasi Universitas Tarumanagara, yang telah memberikan dukungan, kesempatan, dan nasihat berharga selama penulis menempuh perkuliahan.
2. Ibu Ir. Jeanny Pragantha, M.Eng. Selaku Koordinator Skripsi, yang telah memberikan pengarahan, bimbingan, dan koordinasi sehingga penulis dapat menyusun proposal ini dengan baik.

3. Bapak Tri Sutrisno, S.SI., M.Sc. dan Bapak Novario Jaya Perdana, S.kom, M.M.
Selaku dosen pembimbing skripsi Fakultas Teknologi Informasi Universitas Tarumanagara yang telah bersedia meluangkan waktu, pengarahan, dan motivasi kepada penulis dari awal hingga akhir penulisan proposal skripsi.
4. Seluruh dosen Fakultas Teknologi Informasi Universitas Tarumanagara yang dengan tulus berbagi ilmu, wawasan, dan pengalaman sehingga sangat bermanfaat bagi penulis dalam mengembangkan pengetahuan.

Penulis menyadari bahwa skripsi ini masih terdapat kekurangan baik dari segi isi materi, analisis, maupun penyajian, karena keterbatasan pengetahuan dan pengalaman yang dimiliki. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi perbaikan dan pengembangan di masa mendatang.

Akhir kata, penulis berharap semoga skripsi ini dapat memberikan manfaat serta kontribusi dalam pengembangan penelitian.

Jakarta, Februari 2026



Nico Thomas

DAFTAR ISI

HALAMAN JUDUL	i
LEMBAR PENGESAHAN	ii
ABSTRAK	iii
KATA PENGANTAR.....	iv
DAFTAR ISI	vi
DAFTAR GAMBAR	ix
DAFTAR TABEL	ix
DAFTAR LAMPIRAN	xii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Rancangan	4
1.3 Komponen Rancangan.....	5
1.4 Spesifikasi Rancangan.....	11
1.5 Kegunaan Rancangan	16
1.5.1 Manfaat Praktis.....	16

1.5.2 Manfaat Akademis	17
1.6 Rancangan Yang Sudah Dibuat	17
BAB II LANDASAN TEORITIK	23
2.1 Sistem yang dirancang.....	23
2.2 Dasar Teori Sistem yang Dirancang	28
2.2.1 Tinjauan Umum Perencanaan Perjalanan Wisata	28
2.2.2 OpenStreetMap (OSM) Sebagai Sumber Data POI	29
2.2.3 General Transit Feed Specification (GTFS).....	30
2.2.4 Ekstraksi Data dari Dokumen PDF	31
2.2.5 Retrieval-Augmented Generation (RAG)	32
2.2.6 Intelligent K-Means <i>Clustering</i>	35
2.2.7 Algoritma Greedy Nearest Neighbor untuk Optimasi Rute.....	45
BAB III RANCANGAN DAN PEMBUATAN	49
3.1 Rancangan Sistem.....	49
3.1.1 Tahap Perencanaan	50
3.1.2 Tahap Analisis	52
3.1.3 Tahap Perancangan	59
3.2 Pembuatan Sistem.....	65

3.2.1 Skema Pengumpulan Data.....	66
3.2.2 Skema Pra-pemrosesan dan Integrasi Data.....	70
3.2.3 Skema Pembuatan <i>Embedding</i> dan Pencarian Semantik (RAG)	74
3.2.4 Skema Perhitungan Fitur Spasial untuk <i>Clustering</i>	79
3.2.5 Skema Penentuan Jumlah <i>Cluster</i> Optimal.....	84
3.2.6 Skema <i>Clustering</i> dengan Intelligent K-Means.....	84
3.2.7 Skema Interaksi Pemilihan destinasi dalam <i>Cluster</i> oleh Pengguna	88
3.2.8 Skema Optimasi Rute dengan Greedy Nearest Neighbor	89
3.2.9 Skema Visualisasi dan Antarmuka Pengguna	90
DAFTAR PUSTAKA.....	93
LAMPIRAN	98

DAFTAR GAMBAR

Gambar 2. 1 Alur Rancangan Perhitungan Data dan <i>Clustering</i>	27
Gambar 3. 1 Diagram Alur Sistem	50
Gambar 3. 2 Spesifikasi Laptop	54
Gambar 3. 3 Arsitektur Sistem	61
Gambar 3. 4 DFD Level 0 (Context Diagram)	62
Gambar 3. 5 DFD Level 1 (Proses Utama)	63
Gambar 3. 6 DFD Level 2 (Pencarian Semantik)	64
Gambar 3. 7 DFD Level 2 (Intelligen K-Means Clustering)	65
Gambar 3. 8 Proses Pengumpulan Data	67
Gambar 3. 9 Skema Pengumpulan Data	74
Gambar 3. 10 Proses Pencarian Semantik RAG	78
Gambar 3. 11 Diagram Alir Perhitungan Fitur	83
Gambar 3. 12 Diagram Alur Intelligent K-Means	88
Gambar 3. 13 Halaman Input	91
Gambar 3. 14 Halaman Pemilihan Destinasi dalam Cluster	92
Gambar 3. 15 Halaman Visualisasi dalam Peta	92
Gambar L 1.3 Data Destinasi Yang Diekstrak.....	99
Gambar L 5.2 Visualisasi Peta dengan Rute Teroptimasi (Garis Lurus)	131

DAFTAR TABEL

Tabel 1. 1 Tampilan Ikhtisar Dari Studi Rancangan Sebelumnya.....	17
Tabel 3. 1 Ringkasan Kebutuhan Analisis Penggunaan Perangkat.....	57
Tabel 3. 2 Keterangan Fitur	82
Tabel L 2. 1 Atribut Data POI untuk <i>Embedding</i>	100
Tabel L 2. 2 Representasi Teks POI (Contoh 3 POI)	101
Tabel L 2. 3 Vektor <i>Embedding</i>	102
Tabel L 2. 4 Hasil Perhitungan Cosine Similarity untuk Semua POI	104
Tabel L 3. 1 Data POI OSM (Atribut Spasial).....	105
Tabel L 3. 2 Data Halte Transjakarta	106
Tabel L 3. 3 Jarak POI ke Hotel	108
Tabel L 3. 4 Perhitungan Jarak Monas ke Berbagai Halte	109
Tabel L 3. 5 Jarak ke Halte Terdekat	109
Tabel L 3. 6 Fasilitas dalam Radius 500m dari Gedung Kesenian Jakarta	110
Tabel L 3. 7 Jumlah Fasilitas dalam Radius 500m	111
Tabel L 3. 8 Fitur Data Geospasial Untuk Clustering	111
Tabel L 4. 1 Data Fitur-Fitur POI.....	115
Tabel L 4. 2 Langkah perhitungan normalisasi data z-score	117
Tabel L 4. 3 Hasil Perhitungan Normalisasi Data	117
Tabel L 4. 4 Hasil perhitungan WCSS per data (data ke-1)	118
Tabel L 4. 5 Hasil SUM keseluruhan data pada WCSS k=3	119
Tabel L 4. 6 Perhitungan Silhouette (k=3)	119

Tabel L 4. 7 Nilai WCSS dan Silhouette untuk Berbagai k	120
Tabel L 4. 8 Perhitungan manual Centroid dengan data ke-7	121
Tabel L 4. 9 Inisialisasi centroid untuk masing-masing fitur	121
Tabel L 4. 10 Inisialisasi centroid dengan Intelligent K-Means iterasi ke-1	122
Tabel L 4. 11 Perhitungan jarak Ecludian antar data	123
Tabel L 4. 12 Hasil jarak Euclidean seluruh data dengan <i>cluster</i>	123
Tabel L 4. 13 Hasil Alokasi Data.....	124
Tabel L 4. 14 Perhitungan fungsi objektif	125
Tabel L 4. 15 Hasil pembaruan akhir iterasi Intelligent K-Means titik centroid..	126
Tabel L 4. 16 Rata-rata jarak intra-cluster.....	127
Tabel L 4. 17 Jarak hasil antar tiap <i>centroid masing-masing</i>	127
Tabel L 4. 18 Perhitungan untuk menghasilkan rasio R	127
Tabel L 4. 19 Hasil akhir nilai maksimum R tiap <i>cluster</i>	127
Tabel L 5. 2 Data POI koordinat.....	129
Tabel L 5. 3 Matriks jarak antar POI (dalam meter)	130
Tabel L 5. 4 Urutan kunjungan hasil Greedy Nearest Neighbor	131

DAFTAR LAMPIRAN

LAMPIRAN 1 DATASET.....	98
LAMPIRAN 2 PERHITUNGAN PENCARIAN SEMANTIK.....	100
LAMPIRAN 3 PERHITUNGAN FITUR DATA SPASIAL	105
LAMPIRAN 4 PERHITUNGAN INTELLIGENT K-MEANS	114
LAMPIRAN 5 PERHITUNGAN OPTIMASI RUTE	129

BAB I

PENDAHULUAN

1.1 Latar Belakang

Sektor pariwisata menjadi salah satu faktor penting dalam menggerakkan perekonomian global, termasuk di wilayah Asia Tenggara. Berdasarkan laporan dari *World Tourism Barometer* pada bulan Januari 2025 yang diterbitkan oleh UN Tourism, disebutkan bahwa jumlah perjalanan wisatawan internasional pada tahun 2024 mencapai sekitar 1,4 miliar perjalanan, mendekati capaian sebelum pandemi [22]. Pertumbuhan ini memperkuat posisi pariwisata sebagai sektor strategis yang mendorong pertumbuhan ekonomi, mobilitas global, dan layanan pariwisata berbasis digital.

Di sisi lain, ada dinamika yang terlihat terkhususnya daerah DKI Jakarta. Berdasarkan laporan resmi Badan Pusat Statistik Provinsi DKI Jakarta pada tahun 2026, jumlah perjalanan wisata domestik ke DKI Jakarta pada Triwulan IV 2025 mencapai 26.677,37 ribu perjalanan, meningkat 2,85 persen dibandingkan periode yang sama tahun sebelumnya. Tingkat hunian hotel berbintang pada Desember 2025 tercatat 59,97 persen dengan rata-rata lama tinggal 1,57 malam dan proporsi tamu asing sebesar 9,07 persen [4]. Data ini menunjukkan tingginya mobilitas wisata, namun dengan durasi kunjungan yang relatif singkat. Kondisi tersebut menuntut sistem perencanaan perjalanan yang mampu menyusun

rencana perjalanan wisata harian secara efisien, terstruktur, dan berbasis kebutuhan nyata wisatawan.

Perencanaan perjalanan wisata atau dapat disebut *itinerary* merupakan persoalan optimasi yang kompleks dan membutuhkan banyak pertimbangan untuk mencapai tujuan perjalanan yang efektif. Perencanaan perjalanan wisata umumnya melibatkan pengurutan destinasi, perhitungan jarak, serta penyesuaian dengan preferensi pengguna. Di sisi lain, keberadaan fasilitas pendukung seperti restoran, minimarket, dan fasilitas seperti transportasi umum menjadi pertimbangan dalam meningkatkan kenyamanan wisatawan dalam bepergian. Dalam konteks pemetaan digital dan analisis spasial, destinasi wisata beserta fasilitas pendukung tersebut direpresentasikan sebagai *Point of Interest*. POI merupakan titik lokasi spesifik di permukaan bumi yang memiliki daya tarik, kegunaan, atau signifikansi tertentu bagi yang ingin mencari informasi destinasi [7]. Setiap POI umumnya memuat informasi atribut yang beragam, seperti nama destinasi, koordinat (lintang dan bujur), kategori tempat, dan data tambahan fasilitas. Penyediaan fasilitas pendukung pariwisata berkontribusi terhadap kenyamanan wisata dan keberlanjutan ekonomi lokal [15]. Oleh sebab itu, fitur fasilitas pendukung perlu dimasukkan sebagai variabel dalam proses pengelompokan destinasi.

Sejumlah penelitian telah melakukan pengembangan sistem rekomendasi perjalanan berbasis optimasi rute dan *clustering*, di mana hasil dari *clustering* dapat meningkatkan relevansi rekomendasi berbasis preferensi [10].

Perbandingan performa menunjukkan bahwa Intelligent K-Means memiliki keunggulan dalam melakukan inisialisasi *centroid* sehingga menghasilkan *cluster* yang lebih stabil dan optimal [11]. Dalam konteks penelitian ini, fitur jarak tempuh, aksesibilitas transportasi, serta ketersediaan fasilitas seperti restoran dan minimarket menjadi variabel numerik dan kategori yang dapat diolah dalam proses Intelligent K-Means untuk membentuk destinasi yang kedekatan karakteristik.

Selain metode *clustering*, pendekatan pencarian semantik berbasis RAG (Retrieval-Augmented Generation) menjadi komponen penting dalam meningkatkan kualitas rekomendasi. RAG memungkinkan model generatif dapat mengakses basis data eksternal sehingga menghasilkan respons lebih kontekstual dan dapat mempengaruhi keputusan wisatawan secara signifikan [14, 17]. Dengan adanya RAG, aplikasi rancangan dengan kombinasi metode *clustering* memungkinkan pemahaman semantik yang lebih mendalam terhadap kebutuhan pengguna dan memberikan pilihan secara kontekstual untuk wisatawan dalam pengambilan keputusan rencana perjalanan wisata yang dilakukan.

Pengelompokan destinasi wisata yang sudah disesuaikan dengan preferensi pengguna, penyusunan rencana perjalanan juga perlu menghadapi tantangan berupa penentuan urutan kunjungan yang paling efisien dalam satu hari. Dengan integrasi algoritma Greedy Nearest Neighbor (GNN) untuk optimasi rute harian. Algoritma heuristik ini dipilih karena kemampuannya dalam menyusun rute perjalanan yang meminimalkan total jarak tempuh antar destinasi

secara cepat dan efektif [6]. Wisatawan dapat menghindari rute yang bolak-balik, menghemat waktu, serta menekan biaya transportasi dengan optimasi rute ini [18].

Selain itu, penelitian ini diharapkan menjadi pembelajaran dan berkontribusi pada pengelolaan pariwisata yang lebih berkelanjutan sesuai dengan pencapaian *Sustainable Development Goals* (SDGs), khususnya tujuan 8 (pekerjaan layak dan pertumbuhan ekonomi) serta tujuan 11 (kota dan komunitas berkelanjutan). Mayvani dkk. (2022) [2] menekankan bahwa distribusi kunjungan yang merata dapat mengurangi tekanan pada destinasi populer dan mendorong pengembangan destinasi baru. Dengan demikian, sistem yang dikembangkan dalam penelitian ini tidak hanya meningkatkan efisiensi dan personalisasi perjalanan, tetapi juga dapat mendukung pengelolaan destinasi yang lebih berkelanjutan.

1.2 Rumusan Rancangan

Berdasarkan Latar Belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana mengintegrasikan data spasial dari OpenStreetMap, data transportasi umum dari GTFS, dan data deskriptif destinasi dari buku panduan wisata ke dalam suatu basis data destinasi yang terstruktur?
2. Bagaimana menerapkan metode Retrieval-Augmented Generation (RAG) dengan model *embedding* untuk menangkap relevansi semantik antara preferensi tekstual pengguna dan informasi destinasi (nama destinasi, kategori,

dan deskripsi), sehingga diperoleh skor relevansi yang menjadi salah satu fitur dalam proses *clustering*?

3. Bagaimana mengelompokkan destinasi wisata menggunakan algoritma Intelligent K-Means dengan mempertimbangkan fitur gabungan yang terdiri dari koordinat geografis (lintang dan bujur), skor relevansi semantik dari RAG, aksesibilitas transportasi umum (frekuensi layanan dan jarak ke halte terdekat), jarak destinasi ke hotel, serta ketersediaan fasilitas pendukung seperti restoran dan minimarket di sekitar destinasi?
4. Bagaimana merancang mekanisme interaktif pengguna dalam memilih destinasi yang sudah dikelompokkan (*clustering*) untuk menyusun rencana perjalanan wisata?
5. Bagaimana mengevaluasi kinerja sistem yang dibangun dari aspek kualitas *clustering* menggunakan metrik Silhouette Coefficient dan WCSS (Within-Cluster Sum of Squares), serta dari aspek pengalaman pengguna melalui uji penerimaan terhadap kemudahan penggunaan, relevansi rekomendasi, dan pengalaman pengguna dalam memilih destinasi yang telah dikelompokkan?

1.3 Komponen Rancangan

Komponen rancangan dalam penelitian ini disusun secara sistematis dengan tujuan untuk memberikan pemahaman yang jelas mengenai proses perancangan sistem perencanaan perjalanan wisata interaktif dengan mengintegrasikan metode Retrieval-Augmented Generation (RAG) dan algoritma Intelligent K-Means.

Komponen pertama yaitu sumber data yang terdiri atas tiga jenis sumber data yang digunakan. Pertama, data POI (*Point of Interest*) yang diperoleh dari OpenStreetMap (OSM) melalui unduhan dari Geofabrik untuk wilayah Indonesia (Jakarta). Data ini berisi berbagai macam variabel seperti nama destinasi, kategori, sub kategori, koordinat geografis (bujur dan lintang), serta *raw_tags* yang memuat informasi tambahan mengenai destinasi (gabungan data dalam bentuk JSON yaitu: nama destinasi, kategori, sub kategori, *cuisine*, *stars*, dan data tambahan lainnya yang bisa pengganti deskripsi POI). Kedua, data transportasi umum dari *General Transit Feed Specification* (GTFS) yang diperoleh dari *Mobility Database* (Data Transportasi Umum Jakarta/Transjakarta), mencakup informasi halte (*stops.txt*) dan jadwal kedatangan (*stop_times.txt*). Ketiga, data deskriptif destinasi yang diekstraksi dari buku panduan resmi pariwisata dalam format PDF, yang memuat informasi setiap destinasi. Ketiga sumber data ini menjadi fondasi utama dalam merancang sistem yang merepresentasikan informasi spasial, aksesibilitas, dan deskriptif yang diperlukan untuk mendapatkan rekomendasi perjalanan yang komprehensif.

Selanjutnya, komponen kedua yaitu persiapan dan integrasi data. Pada komponen ini, data yang diperoleh dari tiga sumber utama perlu melalui proses pembersihan (*data cleaning*) untuk mengatasi masalah seperti data duplikat, nilai kosong, dan data yang tidak relevan. Untuk data OSM, dilakukan pembersihan dengan menghapus POI yang memiliki nama kosong atau koordinat tidak valid. Data GTFS diproses untuk menghitung frekuensi layanan halte (kedatangan bus)

dan jarak terdekat halte ke setiap POI. Data dari buku panduan dengan format PDF diekstraksi menggunakan *pdfplumber*, kemudian dilakukan pembersihan teks dan ekstraksi informasi tambahan seperti informasi nomor telepon dan *website* menggunakan pola *regex*. Setelah itu, dilakukan pencocokan entitas antara POI hasil ekstraksi buku dengan POI OSM menggunakan metode *fuzzy matching* berbasis kemiripan nama dan distrik. POI yang tidak berhasil dicocokkan akan ditambahkan sebagai entitas baru dengan koordinat yang diperoleh melalui *geocoding* alamat. Hasil dari tahap ini yaitu data POI yang menggabungkan informasi spasial, aksesibilitas, dan deskriptif dalam satu kesatuan untuk menjadikan data POI yang lebih kaya secara informasi.

Komponen berikutnya, dilakukan pembentukan representasi data tekstual dengan *embedding*. Setiap entri POI direpresentasikan dalam bentuk dokumen teks yang merupakan gabungan dari nama destinasi, kategori, sub kategori, deskripsi dari buku panduan, dan *raw tags* dari OSM. Dokumen ini kemudian diubah menjadi vektor numerik (*embedding*) menggunakan model “nomic-embed-text” dari *sentence-transformer*. Model ini dipilih karena kemampuannya menangkap makna semantik dari berbagai bahasa, termasuk Bahasa Indonesia dan Inggris. Vektor *embedding* beserta metadata POI disimpan dalam basis data vektor yaitu ChromaDB untuk melakukan pencarian semantik.

Komponen inti dari rancangan ini yaitu menerapkan metode RAG untuk pencarian semantik. Metode ini bertujuan untuk mencari relevansi antara preferensi tekstual pengguna dengan destinasi wisata. Pengguna memasukkan

preferensi dalam bentuk teks bebas (misalnya: “saya ingin mengunjungi museum bersejarah dan mendapatkan pengalaman kuliner di Jakarta”). Teks preferensi tersebut kemudian diubah menjadi vektor menggunakan model *embedding* yang sama dengan pengubahan data vektor POI, lalu dilakukan pencarian kemiripan semantik dengan seluruh vektor POI dengan skor relevansi tertinggi (Top-K) yang menjadi kandidat destinasi untuk diproses lebih lanjut. Skor relevansi ini menjadi salah satu fitur penting dalam proses *clustering*).

Komponen selanjutnya yaitu pembentukan fitur-fitur lain untuk *clustering*. Setiap entri POI kandidat direpresentasikan dalam vektor fitur yang terdiri atas: (1) koordinat geografis (bujur dan lintang) yang telah dinormalisasi; (2) skor relevansi semantik dari hasil RAG; (3) skor aksesibilitas transportasi yang dihitung berdasarkan jarak ke halte terdekat; (4) jarak dari titik awal (hotel) menggunakan rumus Haversine [5]; (5) ketersediaan fasilitas pendukung yang dihitung dari jumlah restoran, dan minimarket dalam radius yang ditentukan (misalnya: 500 meter) dari setiap POI berdasarkan data dari OpenStreetMap. Fitur-fitur ini kemudian dinormalisasi agar memiliki skala yang sama.

Komponen berikutnya adalah menentukan jumlah *cluster* optimal dengan metode *Silhouette Coefficient*. Metode ini dipilih karena kemampuan dalam mengukur kemiripan suatu objek dengan *cluster*-nya sendiri dibandingkan dengan *cluster* tetangganya [1]. Nilai *Silhouette Coefficient* berkisar antara -1 hingga 1, di mana nilai yang memiliki nilai lebih tinggi menunjukkan *clustering* yang lebih baik.

Pada tahap ini, pengujian nilai k dimulai dari 2 hingga 10, kemudian memilih nilai k dengan skor tertinggi sebagai jumlah *cluster* yang akan digunakan.

Setelah jumlah *cluster* ditentukan, dilakukan pengelompokan dengan algoritma Intelligent K-Means. Algoritma ini merupakan penyempurnaan dari K-Means standar dengan mengoptimalkan pemilihan *centroid* awal berdasarkan probabilitas jarak, sehingga menghasilkan *clustering* yang lebih stabil dan konvergen lebih cepat [7, 9]. Proses pengelompokan dilakukan pada kandidat data POI ke dalam sejumlah *cluster* yang masing-masing merepresentasikan kelompok destinasi dengan karakteristik serupa.

Komponen interaktif yang ada pada rancangan ini yaitu mekanisme pemilihan *cluster* yang dapat dilakukan oleh pengguna. Setelah proses *clustering* selesai, sistem menampilkan ringkasan setiap *cluster* atau dapat disebut pilihan perjalanan yang dikelompokkan berdasarkan karakteristik yang mirip, di mana karakteristik dominan berdasarkan rata-rata fitur atau kata kunci yang sering muncul. Pengguna kemudian diminta memilih destinasi dalam *cluster* mana yang akan dikunjungi pada hari pertama. POI dalam *cluster* yang dipilih akan dihapus dari kumpulan pemrosesan data selanjutnya, sehingga tidak muncul lagi di hari berikutnya. Untuk hari kedua, sistem melakukan *clustering* kembali pada sisa POI dengan jumlah hari tersisa sebagai nilai k yang baru. Proses ini diulang hingga seluruh hari terisi.

Setelah *cluster* dipilih yang dimasukkan ke suatu hari, dilakukan penyusunan rute harian dengan algoritma Greedy Nearest Neighbor [3, 13].

Algoritma ini bekerja dengan memulai perjalanan dari titik hotel, kemudian memilih POI terdekat yang belum dikunjungi, dan mengulangi proses hingga semua POI dalam *cluster* tersebut terpakai. Jarak antar POI dihitung menggunakan rumus Haversine untuk mempertimbangkan kelengkungan bumi [5]. Hasilnya adalah urutan kunjungan yang meminimalkan jarak tempuh dalam suatu hari.

Komponen selanjutnya dari keseluruhan proses terjadi yaitu memvisualisasikan hasil susunan perjalanan yang terpilih. Tahap ini penting dalam penyajian informasi hasil analisis ke dalam bentuk visual yang dapat dipahami dan dilihat secara jelas kepada pengguna, seperti peta interaktif dan susunan rencana perjalanan destinasi wisata. Visualisasi peta menampilkan titik hotel, titik-titik destinasi dengan penanda urutan kunjungan, serta garis rute perjalanan. Selain itu, ditampilkan pula informasi detail setiap destinasi seperti nama, deskripsi singkat dari buku panduan, dan perkiraan jarak tempuh.

Pada komponen terakhir, dilakukan interpretasi hasil dan evaluasi. Hasil dari pengelompokan yang telah terbentuk dianalisis untuk menemukan makna yang relevan dengan konteks perencanaan perjalanan wisata. Interpretasi bertujuan untuk menghubungkan hasil analisis dengan kebutuhan praktis pengguna, sehingga dapat dijadikan dasar dalam memilih rencana perjalanan yang paling sesuai. Evaluasi kinerja sistem dilakukan dari dua aspek, yaitu evaluasi teknis menggunakan *Silhouette Coefficient* dan *WCSS (Within-Cluster Sum of Squares)* untuk mengukur kualitas *clustering*, kemudian evaluasi pengalaman pengguna melalui uji penerimaan dengan melibatkan responden untuk menilai

pengalaman pengguna menggunakan sistem, relevansi rekomendasi, dan kepuasan terhadap sistem [2]. Dengan komponen-komponen rancangan ini, diharapkan sistem yang dibangun dapat menjadi pendukung dalam mengambil keputusan strategis dalam melakukan perencanaan perjalanan wisata yang lebih berbasis data dan personal.

1.4 Spesifikasi Rancangan

Spesifikasi rancangan dalam penelitian ini mencakup modul-modul utama yang akan dikembangkan untuk membangun sistem rekomendasi rencana perjalanan wisata berbasis RAG dan Intelligent K-Means. Setiap modul dirancang secara terintegrasi untuk menghasilkan rencana perjalanan yang personal, efisien, dan kontekstual. Berikut adalah uraian masing-masing modul.

1. Modul Akuisisi dan Integrasi Data

Modul ini bertugas dalam mengumpulkan, membersihkan, dan mengintegrasikan data dari tiga sumber utama. Data OpenStreetMap (OSM) diunduh dari Geofabrik dan mencakup atribut seperti nama destinasi, kategori, sub kategori, lintang, bujur, serta *raw_tags* yang berisi *metadata* seperti nomor telepon, *cuisine*, dan informasi fasilitas tambahan (tidak semua atribut dan data ada). Data GTFS (General Transit Feed Specification) diperoleh dari Mobility Database, dengan dua *file* utama yaitu *file stops* yang berisi informasi halte (koordinat halte) yang mencatat jadwal kedatangan. Data buku panduan wisata berasal dari PDF "*The Official Jakarta Tourism Guidebook*" serta dokumen panduan Bandung, yang diekstraksi menggunakan *library pdfplumber* dan

dilanjutkan dengan *parsing* berbasis pola untuk mengidentifikasi entitas POI beserta deskripsi, alamat, kontak, dan media sosialnya. Ketiga sumber data ini kemudian diintegrasikan melalui pencocokan entitas menggunakan *fuzzy matching* (*library thefuzz*) untuk mencocokkan POI dari buku panduan dengan data OSM berdasarkan kemiripan nama dan distrik. Untuk POI yang tidak ditemukan di OSM, dilakukan pencarian koordinat menggunakan Nominatim berdasarkan alamat yang tersedia.

2. Modul Pencarian Semantik Berbasis RAG

Modul ini bertugas menangkap preferensi pengguna secara semantik dan menghasilkan skor relevansi untuk setiap destinasi. Representasi teks POI dibangun dari gabungan nama destinasi, kategori, sub kategori, deskripsi dan *raw_tags* dengan format terstruktur. Model *embedding* yang digunakan adalah “nomic-embed-text” yang dijalankan melalui Ollama. Proses *embedding* dilakukan untuk setiap teks representasi POI maupun kueri pengguna. Selanjutnya, dihitung cosine similarity antara vektor kueri dan vektor setiap POI menggunakan rumus standar. Hasil perhitungan ini menghasilkan skor relevansi, dan parameter top-K digunakan untuk memilih POI dengan skor tertinggi sebagai kandidat destinasi. Skor relevansi ini akan menjadi salah satu fitur dalam proses *clustering*.

3. Modul Perhitungan Fitur Geospasial

Modul ini menghitung fitur-fitur pendukung untuk setiap POI kandidat. Jarak ke hotel dihitung menggunakan rumus Haversine dengan koordinat hotel yang

ditentukan pengguna. Aksesibilitas transportasi diukur melalui dua indikator: jarak ke halte terdekat (dihitung dengan Haversine terhadap seluruh halte dalam data GTFS) dan frekuensi halte (jumlah kedatangan per hari pada halte terdekat berdasarkan `stop_times.txt`). Kedua indikator ini dikombinasikan menjadi skor aksesibilitas dengan pembobotan tertentu. Fasilitas pendukung seperti restoran dan minimarket dihitung dalam radius 500 meter dari setiap POI dengan cara membandingkan koordinat POI terhadap seluruh titik fasilitas dalam data OSM yang telah diklasifikasikan. Restoran mencakup POI dengan kategori *amenity* dan sub kategori *restaurant*, *cafe*, *fast_food*. Minimarket diidentifikasi melalui nama yang mengandung "Indomaret", "Alfamart", "Circle K", "Family Mart", atau kategori *shop=convenience*. Semua perhitungan jarak menggunakan rumus Haversine.

4. Modul Normalisasi Fitur

Modul ini bertujuan menyeragamkan skala semua fitur numerik agar tidak ada fitur yang mendominasi dalam proses *clustering*. Metode yang digunakan adalah `StandardScaler`, yang mentransformasi setiap fitur sehingga memiliki rata-rata 0 dan standar deviasi 1 dengan rumus z-score. Fitur-fitur yang dinormalisasi meliputi koordinat geografis (lintang dan bujur), skor relevansi dari RAG, jarak ke hotel terdekat, jarak ke halte terdekat, , serta jumlah restoran dan minimarket berada di sekitar POI.

5. Modul *Clustering* dengan Intelligent K-Means

Modul ini mengelompokkan POI kandidat ke dalam sejumlah *cluster* yang akan menjadi dasar pembagian hari perjalanan. Jumlah *cluster* optimal ditentukan menggunakan Silhouette Score dan Elbow Method. Algoritma yang digunakan adalah K-Means yang mengoptimalkan inisialisasi *centroid*, *centroid* pertama dipilih secara acak, kemudian *centroid* berikutnya dipilih dengan probabilitas sebanding dengan kuadrat jarak terpendek ke *centroid* yang sudah ada menggunakan rumus probabilitas. Setelah inisialisasi, dilakukan iterasi di mana setiap titik dialokasikan ke *centroid* terdekat berdasarkan jarak Euclidean, kemudian *centroid* diperbarui dengan rata-rata semua titik dalam *cluster*. Proses ini diulang hingga tidak ada perubahan alokasi atau mencapai iterasi maksimum.

6. Modul Interaktif Pemilihan Destinasi dalam *Cluster*

Modul ini menyediakan antarmuka bagi pengguna untuk memilih kelompok destinasi setiap hari dengan jaminan tidak ada destinasi yang terpakai dua kali. Setelah *clustering* selesai, sistem menyajikan ringkasan setiap *cluster* yang mencakup jumlah POI, rata-rata skor relevansi, rata-rata aksesibilitas, kata kunci dominan, serta contoh POI. Pengguna diminta memilih destinasi dalam *cluster* untuk hari pertama, dan seluruh POI dalam *cluster* terpilih dihapus dari kumpulan data. Untuk hari berikutnya, sistem melakukan *re-clustering* pada sisa POI.

7. Modul Optimasi Rute

Modul ini menyusun urutan kunjungan harian yang meminimalkan total jarak tempuh. Algoritma yang digunakan adalah Greedy Nearest Neighbor, yang bekerja dengan memulai dari titik hotel, kemudian pada setiap langkah memilih POI terdekat yang belum dikunjungi. Proses ini diulang hingga semua POI dalam *cluster* terpakai. Jarak antar titik dihitung menggunakan rumus Haversine, dan total jarak harian dihitung sebagai jumlah seluruh segmen perjalanan.

8. Modul Visualisasi dan Antarmuka Pengguna

Modul ini bertanggung jawab untuk menyajikan hasil rekomendasi dalam bentuk yang mudah dipahami dan interaktif. Antarmuka web dibangun dengan tiga halaman utama: halaman *input* untuk memasukkan jumlah hari, lokasi hotel, preferensi teks, dan filter; halaman pemilihan *cluster* yang menampilkan ringkasan setiap *cluster* dengan tombol pilih; dan halaman hasil yang menampilkan rencana perjalanan per hari dalam bentuk daftar dan peta interaktif. Visualisasi peta menampilkan penanda untuk titik hotel dan setiap POI dengan nomor urut kunjungan, *polyline* berwarna berbeda untuk setiap hari yang menghubungkan rute, serta *popup* yang menampilkan informasi detail POI saat diklik. Tampilan data juga menyertakan tabel ringkasan per hari yang memuat daftar POI berurutan, jarak antar POI, total jarak, serta informasi detail setiap POI, dan jumlah setiap fasilitas pendukung (restoran dan minimarket di sekitar POI).

9. Modul Evaluasi

Modul ini mengukur kualitas sistem dari berbagai aspek. Evaluasi kualitas *clustering* dilakukan menggunakan Silhouette Coefficient untuk mengukur seberapa baik pemisahan antar *cluster*, serta WCSS (inertia) untuk menilai kekompakan internal *cluster*. Evaluasi rute dilakukan dengan membandingkan total jarak tempuh yang dihasilkan sistem terhadap rute acak, serta menghitung efisiensi sebagai persentase pengurangan jarak. Evaluasi pengalaman pengguna dilakukan melalui uji penerimaan dengan kuesioner yang meliputi aspek kemudahan penggunaan sistem, relevansi rekomendasi dengan preferensi, kejelasan informasi yang ditampilkan, dan kepuasan terhadap rute yang dihasilkan.

1.5 Kegunaan Rancangan

Rancangan ini diharapkan dapat memberikan manfaat baik secara praktis maupun akademis.

1.5.1 Manfaat Praktis

1. Membantu pengguna dalam menyusun rencana perjalanan wisata yang efisien dengan sistem otomatisasi yang memberi pilihan karakteristik perjalanan yang beragam.
2. Menangkap preferensi tekstual pengguna secara semantik dengan data POI, sehingga menghasilkan rekomendasi destinasi wisata yang sesuai dengan personalisasi pengguna dan menjadi fitur untuk *clustering*.

3. Aplikasi yang dapat mengelompokkan destinasi wisata berdasarkan data-data kedekatan jarak, aksesibilitas transportasi umum, dan fasilitas umum.

1.5.2 Manfaat Akademis

1. Dapat menjadi referensi dalam pengembangan metode hibrida, di mana integrasi RAG untuk pencarian semantik dan Intelligent K-Means untuk pengelompokan spasial dalam satu kerangka kerja.
2. Mempelajari bagaimana pengaplikasian data seperti GTFS dan ketersediaan fasilitas pendukung dalam mendukung fitur untuk *clustering*.

1.6 Rancangan Yang Sudah Dibuat

Beberapa studi yang memiliki relevansi dan dapat mendukung desain penelitian ini, terutama dalam hal pengembangan sistem perencanaan perjalanan wisata, penerapan algoritma *clustering*, pemanfaatan data transportasi umum seperti GTFS, serta integrasi metode pencarian semantik untuk personalisasi rekomendasi. Ikhtisar dari studi-studi ini dapat ditemukan pada Tabel 1.1.

Tabel 1. 1 Tampilan Ikhtisar Dari Studi Rancangan yang Sebelumnya

No	Judul	Penulis	Kesimpulan
1	A Development of Travel Itinerary Planning Application using Traveling Salesman Problem	Rani dkk. (2018)	Penelitian ini mengembangkan aplikasi perencanaan perjalanan berbasis web dengan dua tahap: pengelompokan destinasi per hari menggunakan

	and K-Means <i>Clustering Approach</i>		K-Means <i>Clustering</i> dan pengurutan rute kunjungan menggunakan pendekatan <i>Traveling Salesman Problem</i> (TSP). Hasil pengujian menunjukkan nilai <i>Silhouette Coefficient</i> sebesar 0,8374 yang dianggap sebagai klasifikasi kuat, namun sistem masih memerlukan peningkatan kecepatan pemrosesan dan penanganan kendala tambahan dalam pembuatan rencana perjalanan wisata [1].
2	Sistem Rekomendasi Produk untuk Pelanggan Perusahaan Distribusi	Sebastian dkk. (2023)	Penelitian ini menggabungkan metode K-Means <i>clustering</i> dan Collaborative Filtering untuk merekomendasikan produk kepada pelanggan PT Enseval. Data transaksi sales periode 2021-2022 digunakan sebagai

	Menggunakan Metode Collaborative Filtering dan K-Means <i>Clustering</i>		dataset. Hasil pengujian menunjukkan bahwa metode Collaborative Filtering tunggal memperoleh nilai Mean Absolute Error (MAE) sebesar 0,1146, sedangkan gabungan K-Means dan Collaborative Filtering memperoleh rata-rata MAE 0,1584. Penelitian ini menyimpulkan bahwa metode K-Means kurang efektif jika digabungkan dengan Collaborative Filtering karena jumlah data transaksi sangat mempengaruhi akurasi rekomendasi. Evaluasi <i>clustering</i> menggunakan Davies Bouldin Index (0,718) dan Silhouette Coefficient (0,747) menunjukkan hasil klasterisasi yang cukup baik dan 80%
--	---	--	---

			peserta setuju bahwa POI dan jalur lebih mudah ditemukan menggunakan Aurigo dibandingkan Google Maps [19].
3	Persuasive or Neutral? A Field Experiment on Generative AI in Online Travel Planning	Jirpongopas dkk. (2025)	Eksperimen lapangan acak pada platform perencanaan rencana perjalanan wisata menunjukkan bahwa pengguna yang berinteraksi dengan chatbot antusias menulis <i>prompt</i> lebih panjang, sementara nada antusias dan netral meningkatkan kemungkinan pembelian langganan. Penelitian ini memberikan implikasi penting untuk desain antarmuka GenAI yang persuasif dan menarik dalam konteks perencanaan perjalanan [10].

4	Implementing K-Means <i>Clustering</i> Algorithm in Collaborative Trip Advisory and Planning System	Yen Yee et al. (2019)	Penelitian ini mengusulkan sistem <i>trip advisory and planning</i> kolaboratif berbasis web dengan algoritma K-Means untuk mengelompokkan tempat wisata berdasarkan kedekatan geografis. Sistem memungkinkan pengguna memilih opsi <i>auto-arrange</i> yang menugaskan tempat berdekatan ke hari yang sama untuk menghemat biaya transportasi dan waktu, serta menyediakan area diskusi bagi semua peserta perjalanan [6].
---	---	-----------------------	---

Berbeda dengan penelitian-penelitian sebelumnya, penelitian ini mencoba untuk mengintegrasikan metode seperti Retrieval-Augmented Generation (RAG) dan algoritma Intelligent K-Means secara simultan untuk merancang sistem perjalanan wisata yang berbasis pada pemahaman semantik dan analisis spasial. Penelitian-penelitian sebelumnya hanya mencoba untuk menggunakan metode *clustering* atau pencarian berbasis teks secara terpisah, sedangkan penelitian ini

mengombinasikan kedua pendekatan untuk menghasilkan sistem perencanaan perjalanan untuk mempermudah pengguna untuk mengambil keputusan dalam menyusun rencana perjalanan wisata dari segi preferensi dan efisien secara geografis. Selain itu, penelitian ini juga mengoptimalkan urutan kunjungan menggunakan algoritma *Greedy Nearest Neighbor*, menjadikan rancangan sistem ini lebih komprehensif dan praktis.

BAB II

LANDASAN TEORITIK

2.1 Sistem yang dirancang

Sistem yang dirancang dalam penelitian ini bertujuan untuk membantu wisatawan dalam menyusun rencana perjalanan wisata yang personal dan efisien dengan mengintegrasikan data spasial, data transportasi umum, serta informasi deskriptif dari buku panduan wisata. Sistem ini berupa aplikasi berbasis web interaktif yang menggabungkan metode Retrieval-Augmented Generation (RAG) untuk pencarian semantik preferensi pengguna dan algoritma Intelligent K-Means untuk pengelompokan destinasi wisata berdasarkan fitur gabungan. Data yang digunakan dalam penelitian berasal dari tiga sumber utama: (1) data Point of Interest (POI) dari OpenStreetMap (OSM) wilayah DKI Jakarta yang telah melalui proses pembersihan dan menghasilkan M data POI dengan atribut seperti *osm_id*, nama, kategori, subkategori, koordinat (lintang dan bujur), serta *raw tags*; (2) data transportasi umum dari General Transit Feed Specification (GTFS) yang mencakup 17.461 halte; dan (3) data deskriptif destinasi yang diekstraksi dari buku panduan resmi pariwisata Jakarta (*The Official Jakarta Tourism Guidebook*) dalam format PDF, yang memuat deskripsi, alamat, fasilitas, serta informasi kontak setiap destinasi.

Berdasarkan data tersebut, sistem analisis ini bekerja melalui beberapa tahapan terstruktur. Pertama, dilakukan proses pra-pemrosesan dan integrasi

data untuk membersihkan, menstandarkan, dan menggabungkan data dari ketiga sumber. Data OSM dibersihkan dari duplikasi dan nilai kosong, data GTFS diproses untuk menghitung frekuensi halte dan jarak terdekat ke setiap POI, dan data PDF diekstraksi serta dicocokkan dengan POI OSM menggunakan metode *fuzzy matching* untuk menghasilkan data POI yang diperkaya (enriched). Tahap berikutnya adalah pembentukan representasi teks dan embedding, di mana setiap POI direpresentasikan sebagai dokumen teks gabungan (nama, kategori, deskripsi, raw tags) yang kemudian diubah menjadi vektor numerik menggunakan model 'nomic-embed-text'. Vektor ini disimpan dalam basis data vektor ChromaDB untuk memudahkan pencarian semantik.


Selanjutnya, sistem menerima input dari pengguna yang meliputi jumlah hari perjalanan, titik awal (hotel), preferensi tekstual (misalnya "saya suka tempat bersejarah dan kuliner malam"), serta filter opsional seperti wilayah atau kategori. Input preferensi tekstual diubah menjadi vektor dan dilakukan pencarian kemiripan semantik dengan seluruh vektor POI menggunakan cosine similarity, menghasilkan sejumlah POI kandidat (top-K) beserta skor relevansinya. POI kandidat ini kemudian diproses untuk menghitung fitur-fitur *clustering*: koordinat geografis (dinormalisasi), skor relevansi semantik, skor aksesibilitas transportasi (jarak ke halte), jarak ke hotel (menggunakan rumus Haversine), serta ketersediaan fasilitas pendukung (jumlah restoran dan minimarket dalam radius misalnya 500 meter berdasarkan data OSM). Fitur-fitur ini dinormalisasi.

Tahap inti adalah penentuan jumlah *cluster* optimal dengan metode Silhouette Coefficient. Setelah *k* optimal diperoleh, dilakukan pengelompokan menggunakan algoritma Intelligent K-Means yang mengoptimalkan inisialisasi centroid awal sehingga menghasilkan kelompok destinasi yang stabil dan bermakna. Hasil *clustering* berupa beberapa kelompok destinasi dengan karakteristik berbeda, yang kemudian disajikan kepada pengguna dalam antarmuka interaktif. Pengguna diminta memilih kelompok destinasi untuk setiap hari perjalanan; destinasi dalam kelompok yang dipilih akan dihapus dari kumpulan data sehingga tidak muncul kembali di hari berikutnya. Untuk setiap hari, sistem menyusun rute kunjungan optimal menggunakan algoritma Greedy Nearest Neighbor dengan titik awal hotel, menghasilkan urutan kunjungan yang meminimalkan jarak tempuh harian. Seluruh hasil ditampilkan dalam bentuk daftar perjalanan per hari, dilengkapi deskripsi destinasi dari buku panduan, total jarak, estimasi waktu, serta visualisasi peta interaktif.

Dengan demikian, sistem yang dirancang pada penelitian ini merupakan kerangka analisis data terintegrasi yang dimulai dari pengumpulan data multi-sumber, pemrosesan, pencarian semantik, *clustering*, hingga penyajian hasil secara interaktif. Output akhir diharapkan dapat membantu wisatawan dalam merencanakan perjalanan yang lebih personal, efisien, dan sesuai dengan preferensi serta kebutuhan aksesibilitas mereka.

Proses perhitungan data dalam sistem ini dimulai dengan pengambilan data dari tiga sumber: OSM, GTFS, dan PDF buku panduan. Data tersebut

kemudian melalui tahap pra-pemrosesan dan integrasi untuk menghasilkan data POI yang diperkaya. Selanjutnya, data teks POI diubah menjadi vektor embedding dan disimpan dalam basis data vektor. Saat pengguna memberikan input, preferensi tekstual di-embed dan dilakukan pencarian semantik untuk mendapatkan POI kandidat beserta skor relevansi. POI kandidat kemudian dihitung fitur-fitur *clustering* (koordinat, aksesibilitas, jarak hotel, fasilitas) dan dinormalisasi. Setelah itu, dilakukan penentuan jumlah *cluster* optimal dengan Silhouette Coefficient dan *clustering* menggunakan K-Means++. Hasil *cluster* ditampilkan kepada pengguna untuk dipilih per hari, dan untuk setiap hari yang dipilih, rute disusun dengan Greedy Nearest Neighbor. Flowchart tahapan perhitungan ini dapat dilihat pada Gambar 2.1.



Gambar 2. 1 Alur Rancangan Perhitungan Data dan *Clustering*

Tahapan visualisasi dilakukan setelah hasil analisis diperoleh. Proses diawali dengan analisis kebutuhan visualisasi yang sesuai, misalnya peta interaktif dengan penanda (*pin*) dan garis rute, grafik distribusi skor relevansi, serta ringkasan karakteristik setiap *cluster*. Data hasil analisis, termasuk daftar POI per hari, urutan kunjungan, dan deskripsi destinasi, kemudian diproses untuk dibuat menjadi visualisasi (peta) dan ringkasan perencanaan interaktif.

2.2 Dasar Teori Sistem yang Dirancang

2.2.1 Tinjauan Umum Perencanaan Perjalanan Wisata

Perencanaan perjalanan wisata atau bisa disebut *itinerary* merupakan panduan sistematis yang mencakup daftar destinasi selama perjalanan [1]. Komponen-komponen ini saling terkait dan memerlukan pertimbangan yang matang agar wisatawan dapat mengoptimalkan waktu dan sumber daya yang tersedia. Yahi dkk. (2015) [3] menekankan bahwa personalisasi dalam penyusunan *itinerary* menjadi faktor kunci dalam meningkatkan kepuasan pengguna, sementara Yen Yee dkk. (2019) [9] menambahkan bahwa aspek kolaborasi antar anggota kelompok juga penting diperhatikan dalam perencanaan perjalanan bersama.

Meskipun menyusun *itinerary* memberikan banyak manfaat, proses manual masih menghadapi berbagai tantangan. Jirpongopas dkk. (2025) [14] mencatat bahwa 74% wisatawan memanfaatkan aplikasi dalam perencanaan, namun 36,5% di antaranya membutuhkan waktu lebih dari tiga jam untuk menyusun jadwal. Selain itu, optimalisasi rute antar destinasi sering kali tidak efisien jika hanya mengandalkan intuisi, yang dapat mengakibatkan pemborosan waktu dan biaya transportasi [1]. Ketika perjalanan dilakukan secara berkelompok, menyelaraskan preferensi yang beragam juga menjadi tantangan tersendiri [9].

Perkembangan teknologi seperti Retrieval-Augmented Generation (RAG) dan algoritma Intelligent K-Means menawarkan solusi untuk mengatasi tantangan tersebut. Swacha dan Gracel (2025) [17] menjelaskan bahwa RAG mampu

mengintegrasikan basis data eksternal untuk menghasilkan rekomendasi yang lebih kontekstual, sementara Bukhari dan Song (2025) [11] serta Aliguliyev dan Tahirzada (2022) [13] menunjukkan bahwa K-Means unggul dalam pengelompokan data yang stabil dan efisien. Penelitian ini mengintegrasikan kedua pendekatan tersebut untuk membangun sistem rekomendasi perencanaan pariwisata yang mampu mengelompokkan destinasi berdasarkan fitur spasial, aksesibilitas, fasilitas, dan preferensi pengguna, sehingga menghasilkan rencana perjalanan wisata yang lebih terstruktur, efisien, dan personal.

2.2.2 OpenStreetMap (OSM) Sebagai Sumber Data POI

OpenStreetMap (OSM) merupakan proyek kolaborasi internasional yang bertujuan menciptakan peta dunia yang bebas digunakan dan selalu diperbarui oleh komunitas sukarelawan [23]. Berbeda dengan peta komersial, OSM menawarkan akses terbuka terhadap data geospasial yang dapat diunduh, dimodifikasi, dan digunakan untuk berbagai keperluan, termasuk penelitian akademik. OSM menjadi sumber data yang semakin populer karena kelengkapan dan kemutakhirannya [7].

Struktur data OSM terdiri dari tiga elemen dasar:

1. *Node*: Titik yang merepresentasikan objek tunggal dengan koordinat geografis.
2. *Way*: Urutan *node* yang membentuk garis untuk representasi jalan, sungai, atau batas area.
3. *Relation*: Kumpulan *node* dan *way* yang saling berhubungan, misalnya rute transportasi.

Setiap data dalam OSM dapat diberi *tag* yang berupa pasangan kunci-nilai (*key-value*) untuk mendeskripsikan suatu atribut objek. Misalnya, sebuah restoran dapat memiliki *tag* “*amenity=restaurant*”. Sistem *tagging* menyimpan informasi untuk memperkaya berbagai jenis POI.

Dalam penelitian ini, OSM digunakan sebagai sumber utama data POI karena beberapa keunggulan, yaitu karena bersifat *open-source* yang dapat diunduh secara gratis melalui sumber seperti Geofabrik atau Geo2Day. Selain itu, atribut-atribut dan elemen-elemen data dapat digunakan sebagai penunjang penelitian ini, di antaranya data koordinat (lintang dan bujur), kategori, sub kategori, *raw_tags*, dan data-data fasilitas pendukung seperti restoran atau minimarket [23].

2.2.3 General Transit Feed Specification (GTFS)

General Transit Feed Specification (GTFS) adalah format data standar yang digunakan untuk menginformasikan jadwal dan informasi geografis sistem transportasi umum. Dikembangkan oleh Google pada tahun 2005, GTFS telah menjadi standar global yang digunakan oleh ribuan operator transportasi di seluruh dunia untuk mempublikasikan data layanan mereka. GTFS memungkinkan integrasi data transportasi publik dalam berbagai aplikasi perencanaan perjalanan [21].

Struktur GTFS terdiri dari serangkaian file teks yang saling terkait, dengan *file stop* yang dipakai dalam penelitian ini berisi daftar halte atau stasiun dengan informasi koordinat geografis (lintang dan bujur), nama halte, dan identifikasi unik

[24]. Vuurstaek dkk. (2020) [7] dalam penelitiannya tentang pemetaan halte bus GTFS ke jaringan OSM menunjukkan bahwa integrasi kedua sumber data ini dapat menghasilkan analisis aksesibilitas yang lebih akurat. Hal ini karena OSM menyediakan informasi detail tentang infrastruktur jalan, sementara GTFS memberikan data operasional transportasi umum.

Dalam konteks penelitian ini, GTFS digunakan untuk menentukan aksesibilitas transportasi yang terdiri dari perhitungan jarak terdekat antara destinasi POI ke halte. Perhitungan aksesibilitas ini menjadi nilai numerik untuk memperkaya fitur *clustering*, sehingga kelompok destinasi yang terbentuk mempertimbangkan kemudahan transportasi umum. Data GTFS yang digunakan dalam penelitian ini diperoleh dari operator transportasi umum di Jakarta, seperti Transjakarta, yang menyediakan data mereka secara terbuka melalui portal Mobility Database atau situs resmi. Data tersebut mencakup ribuan halte dan ratusan ribu jadwal kedatangan, yang kemudian diproses untuk menghasilkan indikator aksesibilitas bagi setiap POI.

2.2.4 Ekstraksi Data dari Dokumen PDF

Data buku panduan wisata diperoleh dari dua sumber dokumen PDF: "*The Official Jakarta Tourism Guidebook*". Proses ekstraksi menggunakan *library pdfplumber* menghasilkan 140 entri POI. Setiap entri mencakup informasi seperti nama destinasi, alamat, deskripsi, nomor telepon, alamat *website*, dan akun media sosial. Setelah melalui proses pembersihan teks dan ekstraksi informasi spesifik menggunakan regular expression, data ini kemudian dicocokkan dengan data OSM

menggunakan metode fuzzy matching. Pencocokan entitas antara data buku panduan dan data OSM dilakukan dengan menggunakan library *thefuzz* (*fuzzywuzzy*). Metode *token_sort_ratio* dipilih karena mampu menangani variasi urutan kata pada nama destinasi.

2.2.5 Retrieval-Augmented Generation (RAG)

2.2.5.1 Konsep Dasar Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) merupakan pendekatan dalam pengembangan sistem kecerdasan buatan yang menggabungkan kemampuan pencarian informasi (*retrieval*) dengan kemampuan generatif model bahasa besar (*Large Language Model* / LLM). RAG dirancang untuk mengatasi keterbatasan utama LLM yang hanya mengandalkan data pelatihan statis dan tidak memiliki akses ke informasi terbaru atau spesifik domain tertentu. Pendekatan ini memungkinkan model untuk "berkonsultasi" dengan sumber informasi eksternal sebelum menghasilkan jawaban, sehingga respons yang dihasilkan lebih akurat, faktual, dan kontekstual. Secara konseptual, RAG terdiri dari tiga komponen utama yang bekerja secara berurutan [17]:

1. *Retrieval* (Pengambilan Informasi) : Proses mencari dan mengambil informasi relevan dari basis pengetahuan eksternal berdasarkan kueri pengguna.
2. *Augmentation* (Augmentasi) : Menggabungkan informasi hasil pencarian dengan kueri asli untuk membentuk konteks yang kaya, sering menggunakan templat dengan pemformatan dan instruksi tambahan untuk LLM.

3. *Generation* (Generatif) : Model bahasa menghasilkan respons berdasarkan kombinasi antara pengetahuan internal hasil pelatihan dan konteks eksternal yang baru diberikan.

Ketiga komponen ini membentuk alur kerja yang memungkinkan sistem untuk menjawab pertanyaan dengan merujuk pada sumber informasi yang spesifik dan terverifikasi [14].

2.2.5.2 Komponen Utama Sistem RAG

Implementasi RAG yang efektif memerlukan beberapa komponen teknis yang saling terintegrasi:

1. *Embedding Model*

Embedding adalah representasi numerik dari teks dalam bentuk vektor berdimensi tinggi yang menangkap makna semantik atau kontekstual dari data. *Embedding model* berfungsi mengubah dokumen dan kueri menjadi vektor yang dapat dibandingkan secara matematis. Model seperti *OpenAI Embeddings* atau *Sentence Transformers* menghasilkan vektor yang merepresentasikan makna teks, sehingga dokumen dengan topik serupa akan memiliki vektor yang berdekatan dalam ruang multidimensi. Pemilihan model *embedding* yang tepat sangat menentukan kualitas pencarian semantik, dengan faktor pertimbangan meliputi dukungan bahasa, dimensi vektor, kebutuhan komputasi, dan kemampuan *self-hosting* [16].

2. Basis Data Vektor

Vektor *embedding* yang dihasilkan perlu disimpan dalam basis data yang dioptimalkan untuk pencarian kemiripan. Basis data vektor seperti ChromaDB memungkinkan pencarian berbasis kesamaan semantik dengan cepat dan efisien. Basis data ini menyimpan pasangan antara vektor *embedding* dan teks asli beserta metadatanya, sehingga ketika ada kueri, sistem dapat mencari vektor yang paling mirip dan mengembalikan teks terkait.

3. *Retriever Engine*

Retriever bertugas mengambil *top-K* dokumen atau potongan teks yang paling relevan dari basis data vektor berdasarkan kueri pengguna. Proses ini umumnya menggunakan metrik kemiripan seperti *cosine similarity* untuk mengukur kedekatan antar vektor [16]. Hasil retrieval kemudian diperingkatkan untuk memastikan bahwa konteks yang paling relevan digunakan dalam tahap generasi.

4. Large Language Model (LLM)

LLM berfungsi sebagai model generatif yang menyusun jawaban akhir berdasarkan kombinasi kueri pengguna dan konteks yang telah diterima. Model seperti Llama dapat dijalankan secara lokal melalui platform seperti Ollama untuk menjaga privasi data [14].

2.2.6.3 Penerapan RAG dalam Sistem Rekomendasi Perjalanan

Dalam konteks sistem rekomendasi perjalanan wisata, RAG menawarkan pendekatan yang sangat relevan untuk mengintegrasikan preferensi pengguna dengan basis pengetahuan destinasi yang kaya. Penelitian oleh Akmal dkk. (2025)

[6] menunjukkan bahwa RAG mampu secara efektif mengintegrasikan data dari berbagai sumber seperti dokumen PDF, basis data, dan API eksternal untuk menghasilkan rekomendasi yang personal dan kontekstual. Penerapan RAG dalam sistem ini dilakukan melalui langkah-langkah berikut:

1. Pembangunan basis pengetahuan: Data POI dari OpenStreetMap, informasi fasilitas, dan deskripsi dari buku panduan wisata diintegrasikan dan di-*embed* ke dalam basis data vektor.
2. Pemrosesan kueri pengguna: Preferensi pengguna dalam bentuk teks bebas di-*embed* menggunakan model yang sama.
3. Pencarian semantik: Sistem mencari POI dengan vektor paling mirip menggunakan metrik cosine similarity [16].

$$\text{Cosine_similarity}(\bar{A}, \bar{B}) = \frac{\bar{A} \cdot \bar{B}}{\|\bar{A}\| \cdot \|\bar{B}\|} \quad (2,1)$$

$\bar{A}$ = Data POI Destinasi

$\bar{B}$ = Kueri Pengguna

4. Augmentasi konteks: Informasi POI yang relevan digabungkan dengan kueri asli untuk membentuk prompt yang kaya.
5. Generasi rekomendasi: LLM menghasilkan rekomendasi destinasi beserta penjelasan naratif yang personal.

2.2.6 Intelligent K-Means *Clustering*

Clustering atau pengelompokan merupakan salah satu teknik utama dalam analisis data tak berlabel yang bertujuan untuk membagi data ke dalam kelompok-

kelompok sehingga data dalam satu kelompok memiliki kemiripan karakteristik yang tinggi, sementara antar kelompok memiliki perbedaan yang signifikan [9]. Dalam konteks sistem rekomendasi perjalanan, *clustering* digunakan untuk mengelompokkan destinasi wisata berdasarkan berbagai fitur, sehingga wisatawan dapat memperoleh rekomendasi yang lebih terstruktur dan sesuai preferensi [1].

Pada penelitian ini, algoritma Intelligent K-Means diterapkan untuk mengelompokkan destinasi wisata berdasarkan fitur gabungan yang terdiri dari aspek spasial (koordinat lintang dan bujur), skor relevansi semantik, aksesibilitas transportasi, dan fasilitas pendukung (restoran dan minimarket). Pemilihan fitur yang tepat menjadi kunci agar *cluster* yang dihasilkan dapat merepresentasikan karakteristik destinasi yang relevan dengan kebutuhan wisatawan.

2.2.6.1 Pemilihan Fitur untuk *Clustering*

Tahap awal sebelum melakukan *clustering* yaitu menentukan variabel numerik yang digunakan sebagai fitur untuk pembentuk *cluster*. Variabel ini harus bisa menjadi fitur yang dapat merepresentasikan karakteristik destinasi dan dapat dihitung jaraknya secara matematis. Variabel yang digunakan dalam penelitian ini terdiri dari:

1. koordinat geografis: lintang dan bujur yang mencerminkan lokasi spasial destinasi.
2. Skor relevansi semantik: skor relevansi destinasi dengan preferensi pengguna.

3. Jarak destinasi ke halte (meter): jarak terpendek halte dengan destinasi POI menggunakan rumus Haversine.
4. Jarak destinasi ke hotel (meter): jarak terpendek hotel dengan destinasi POI menggunakan rumus Haversine.
5. Jumlah restoran di sekitar destinasi POI.
6. Jumlah minimarket di sekitar destinasi POI.

2.2.6.2 Normalisasi Data

Fitur-fitur yang digunakan dalam *clustering* seringkali memiliki satuan dan rentang nilai yang berbeda (seperti data koordinat, satuan jarak, dan jumlah fisik). Jika tidak dinormalisasi, fitur dengan skala besar akan mendominasi perhitungan jarak sehingga mengurangi kualitas *cluster* [10]. Oleh karena itu, normalisasi data menjadi langkah penting sebelum proses *clustering*. Metode yang digunakan adalah z-score standardization:

$$z = \frac{x - \mu}{\sigma} \quad (2.2)$$

z = nilai hasil normalisasi,

x = nilai fitur,

μ = rata-rata fitur,

σ = Standar deviasi fitur.

Normalisasi ini bertujuan untuk mengubah skala data seluruh variabel menjadi sebanding, sehingga tidak ada fitur yang mendominasi perhitungan jarak pada algoritma.

2.2.6.3 Penentuan Jumlah *Cluster* (k)

Salah satu tantangan utama dalam *clustering* adalah menentukan jumlah *cluster* yang optimal. Pada penelitian ini, jumlah *cluster* optimal ditentukan dengan dua pendekatan:

Elbow Method (WCSS)

Metode Elbow bekerja dengan menghitung nilai Within-Cluster Sum of Squares (WCSS) untuk berbagai nilai k , kemudian memilih titik di mana penurunan WCSS mulai melambat (membentuk siku). Nilai k pada titik tersebut dianggap optimal [19].

$$WCSS = \sum_{i=1}^k \sum_{j=1}^k r_{ij} \|x_i - c_j\|^2$$

(2.3)

x_i = data ke- i ,

c_j = centroid *cluster* ke- j ,

r_{ij} = indikator keanggotaan data ke- i pada *cluster* ke- j ,

k = jumlah *cluster*,

n = jumlah data.

Silhouette Coefficient

Silhouette Coefficient mengukur seberapa mirip suatu objek dengan *cluster*-nya sendiri dibandingkan dengan *cluster* tetangganya.

$$s(i) = \frac{b(i) - a(i)}{\max \{a(i), b(i)\}}$$

(2.4)

$a(i)$ = rata-rata jarak data i ke semua data dalam *cluster* yang sama,

$b(i)$ = rata-rata jarak data i ke *cluster* terdekat,

$s(i) \in [-1, 1]$

Interpretasi:

$(i) \approx 1$: data sangat tepat dalam *cluster*-nya,

$s(i) \approx 0$: data berada di batas antar *cluster*,

$s(i) \approx -1$: data salah masuk *cluster*.

Nilai $s(i)$ berada pada interval $[-1, 1]$. Nilai mendekati 1 menunjukkan bahwa data cocok dengan *clusternya*, nilai mendekati 0 berarti berada di batas antar *cluster*, sedangkan nilai negatif menunjukkan salah pengelompokan.

2.2.6.4 Inisialisasi Centroid dengan Intelligent K-Means

Inisialisasi *centroid* pada Intelligent K-Means menggunakan strategi penyebaran, di mana *centroid* awal dipilih secara acak dan *centroid* berikutnya dipilih berdasarkan probabilitas jarak [11].

Langkah-langkah inisialisasi Intelligent K-Means adalah sebagai berikut:

1. Pilih *centroid* pertama secara acak dari data.
2. Untuk setiap titik data, hitung jarak terpendek $D(x)$ ke *centroid* yang sudah dipilih.
3. Pilih *centroid* berikutnya dengan probabilitas sebanding dengan kuadrat jarak:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in X} D(x')^2} \quad (2.5)$$

$P(x)$ = probabilitas titik x terpilih sebagai *centroid* berikutnya

$D(x)$ = jarak terpendek dari titik x *centroid* yang sudah dipilih

X = himpunan semua titik data.

4. Ulangi langkah 2-3 hingga diperoleh sebanyak k *centroid*.

Pendekatan ini memastikan bahwa *centroid* awal tersebar dengan baik dan mengurangi risiko konvergensi pada optimum lokal [13].

2.2.7.5 Perhitungan Jarak (Euclidean Distance)

Setelah *centroid* ditentukan, jarak antara setiap data dengan *centroid* dihitung menggunakan Euclidean Distance [14]:

$$d(x_i, c_j) = \sqrt{\sum_{p=1}^m (x_{ip} - c_{jp})^2} \quad (2.6)$$

x_{ip} = nilai data ke-i pada variabel ke-p,

c_{jp} = nilai data ke-j pada variabel ke-p,

m = jumlah variabel input.

Rumus ini menghitung jarak dalam ruang multidimensi sehingga sesuai untuk data banyak fitur.

2.2.6.6 Alokasi Data Ke *Cluster*

Setelah inisialisasi *centroid* dilakukan dan jarak setiap data ke *centroid* dihitung, langkah selanjutnya adalah mengalokasikan setiap data ke dalam *cluster* yang paling dekat. Proses alokasi ini merupakan inti dari algoritma K-Means yang menentukan keanggotaan setiap titik data berdasarkan jarak terpendek ke *centroid* [1]. Pada setiap iterasi, setiap titik data akan diperiksa dan ditempatkan ke dalam *cluster* yang memiliki *centroid* dengan jarak Euclidean terkecil.

$$r_{ij} = \begin{cases} 1, & \text{Jika data } x_i \text{ masuk ke cluster } j \\ 0, & \text{lainnya} \end{cases} \quad (2.7)$$

r_{ij} = indikator keanggotaan data i pada *cluster* j .

Nilai $r_{ij} = 1$ berarti data x_i menjadi anggota *cluster* ke- j , dan untuk *cluster* lain nilainya 0. Hal ini sesuai dengan prinsip partisi tegas yang dijelaskan oleh Aliguliyev dan Tahirzada (2022) [13] serta banyak literatur lainnya. Hal ini memastikan setiap data hanya dapat menjadi anggota dari satu *cluster*.

2.2.6.7 Fungsi Objektif (WCSS)

Dalam algoritma K-Means, fungsi objektif yang umum digunakan adalah *Within-Cluster Sum of Squares* (WCSS) atau sering disebut dengan *inertia*. WCSS mengukur jumlah total kuadrat jarak antara setiap titik data dengan *centroid* dari *cluster* tempat titik tersebut berada [1].

$$J = \sum_{i=1}^n \sum_{j=1}^k r_{ij} \|x_i - c_j\|^2 \quad (2.8)$$

J = nilai fungsi objektif,

x_i = data ke- i ,

c_j = centroid cluster ke- j ,

r_{ij} = indikator keanggotaan,

n = jumlah data,

k = jumlah cluster.

Semakin kecil nilai J , semakin baik kualitas clustering.

2.2.6.8 Pembaruan Centroid

Pembaruan *centroid* dilakukan dengan menghitung nilai rata-rata (mean) dari semua data yang menjadi anggota pada setiap *cluster* [9]. Secara matematis, pembaruan *centroid* untuk *cluster* ke- j dinyatakan dengan rumus:

$$c_j = \frac{1}{n_j} \sum_{x_i \in C_j} x_i \quad (2.9)$$

c_j = centroid *cluster* ke- j ,

n_j = jumlah data dalam *cluster* j ,

C_j = himpunan data pada *cluster* j .

Pembaruan ini dilakukan agar centroid lebih representatif terhadap anggota kluster yang dibentuk.

2.2.6.9 Iterasi Hingga Konvergensi

Setelah tahap perhitungan jarak, alokasi data, dan pembaruan *centroid* dilakukan, proses ini tidak berhenti pada satu kali perulangan saja. Algoritma *Intelligent K-Means* secara berulang melakukan langkah-langkah tersebut hingga tercapai kondisi konvergensi [9]. Proses iteratif ini merupakan karakteristik fundamental dari algoritma K-Means yang memungkinkan perbaikan kualitas *cluster* secara bertahap.

Konvergensi didefinisikan sebagai keadaan di mana perpindahan posisi *centroid* antar iterasi berikutnya sudah sangat kecil atau tidak signifikan lagi, sehingga struktur *cluster* yang terbentuk dapat dianggap stabil [13]. Dalam praktiknya, algoritma dianggap konvergen ketika tidak ada lagi perubahan keanggotaan data antar *cluster* atau ketika perubahan nilai *centroid* berada di bawah ambang batas tertentu yang telah ditentukan (Glaret Shirley dkk., 2023) [10]. Selain itu, konvergensi juga dapat dinilai dari nilai fungsi objektif J (WCSS) yang tidak lagi mengalami penurunan berarti. Yen Yee dkk. (2019) [9] menjelaskan bahwa meskipun iterasi tambahan masih memungkinkan, perbaikan

kualitas *cluster* yang diperoleh menjadi semakin minim dan tidak efisien secara komputasi jika penurunan nilai WCSS sudah sangat kecil.

Dalam implementasi algoritma K-Means, terdapat beberapa kriteria yang umum digunakan untuk menghentikan iterasi:

1. Tidak ada perubahan alokasi data: Jika semua data tetap berada pada cluster yang sama seperti iterasi sebelumnya, maka algoritma dihentikan [1].
2. Perubahan posisi centroid minimal: Jika pergeseran posisi *centroid* antar iterasi kurang dari nilai toleransi yang ditentukan (misalnya 10^{-4}), algoritma dianggap telah konvergen [13].
3. Penurunan fungsi objektif tidak signifikan: Jika perubahan nilai WCSS antar iterasi sangat kecil, algoritma dapat dihentikan karena perbaikan yang diperoleh tidak berarti [10].
4. Mencapai jumlah iterasi maksimum: Untuk menghindari perulangan tak terbatas, algoritma biasanya dilengkapi dengan batasan jumlah iterasi maksimum [9].

2.2.6.10 Evaluasi Kualitas *Cluster*

Tahap akhir dari proses *Intelligent K-Means* adalah evaluasi kualitas *cluster* yang dihasilkan. Evaluasi ini penting untuk memastikan bahwa hasil pengelompokan tidak hanya memenuhi fungsi objektif secara matematis, tetapi juga mampu merepresentasikan pola data secara praktis dan bermakna [1]. Dalam penelitian ini digunakan dua metrik evaluasi, yaitu Silhouette

Coefficient dan Davies-Bouldin Index (DBI), yang secara bersama-sama memberikan gambaran komprehensif mengenai kualitas *clustering* [13].

1. *Silhouette Coefficient*

Silhouette Coefficient digunakan untuk mengukur tingkat kohesi internal (kedekatan data dalam satu *cluster*) dan separasi antar *cluster* (jarak antar *cluster* yang berbeda). Nilai koefisien dihitung untuk setiap data, lalu dirata-ratakan untuk seluruh dataset [10]. Untuk setiap titik data i , nilai *silhouette* $s(i)$ didefinisikan sebagai:

2. *Davies-Bouldin Index (DBI)*

Davies-Bouldin Index (DBI) menilai kualitas *cluster* berdasarkan rasio antara dispersi internal *cluster* dengan jarak antar *centroid*. DBI dihitung dengan rumus [13]:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{S_i + S_j}{M_{ij}} \right) \quad (2.10)$$

dengan keterangan:

k = jumlah *cluster*,

S_i = rata-rata jarak titik-titik dalam *cluster* i terhadap centroid i (dispersi internal),

M_{ij} = jarak antar centroid *cluster* i dan j (separasi *cluster*).

Semakin kecil nilai DBI, semakin baik kualitas cluster, karena menunjukkan bahwa cluster memiliki kohesi yang kuat sekaligus terpisah jelas dari cluster lain [19]. Misalnya, pada data sederhana dengan dua cluster {1,2,3} dan {8,9,10}, nilai DBI yang kecil menandakan bahwa cluster terbentuk dengan baik.

3. Kesimpulan Evaluasi

Dengan menggunakan kedua metrik tersebut, evaluasi kualitas *cluster* menjadi lebih objektif. *Silhouette Coefficient* menekankan kualitas keanggotaan tiap data terhadap *cluster*, sedangkan DBI berfokus pada keseimbangan antara kepadatan internal *cluster* dan jarak antar *cluster* [9]. Kombinasi keduanya memastikan bahwa hasil *clustering* tidak hanya optimal secara algoritmik, tetapi juga reliabel dan mendukung proses analisis data lebih lanjut, termasuk dalam konteks sistem rekomendasi perjalanan yang dikembangkan dalam penelitian ini.

2.2.7 Algoritma Greedy Nearest Neighbor untuk Optimasi Rute

2.2.7.1 Konsep Travelling Salesman Problem (TSP) dan Heuristik

Travelling Salesman Problem (TSP) merupakan permasalahan klasik dalam optimasi kombinatorial yang bertujuan untuk menemukan rute perjalanan dengan jarak atau biaya total paling minimum, dimulai dari suatu titik awal, mengunjungi sekumpulan titik lainnya tepat satu kali, dan kembali ke titik awal [1]. Dalam konteks matematis, TSP dapat direpresentasikan sebagai pencarian sirkuit Hamilton dengan bobot minimum pada suatu graf lengkap) [6]. Permasalahan ini dikenal sebagai NP-hard, yang berarti bahwa untuk jumlah titik yang besar, pencarian solusi optimal secara eksak menjadi tidak praktis karena kompleksitas komputasi yang sangat tinggi [18].

Oleh karena itu, pendekatan heuristik menjadi pilihan utama dalam menyelesaikan TSP untuk aplikasi praktis. Heuristik adalah metode yang

digunakan untuk memecahkan masalah dengan pendekatan *trial and error* ketika algoritma eksak dinilai tidak praktis dan tidak efisien untuk menghasilkan solusi [6]. Metode heuristik tidak menjamin solusi optimal global, namun mampu menemukan solusi yang mendekati optimal dalam waktu yang jauh lebih singkat [18]. Beberapa algoritma heuristik yang umum digunakan untuk TSP antara lain *nearest neighbor*, *nearest insertion*, *saving algorithm*, dan *cheapest-insertion heuristics* [1].

2.2.7.2 Algoritma Nearest Neighbor

Algoritma *Nearest Neighbor* (NN) merupakan salah satu metode heuristik yang paling sederhana dan intuitif untuk menyelesaikan TSP [6]. Algoritma ini bekerja dengan prinsip *greedy*, yaitu selalu memilih opsi terbaik pada setiap langkah tanpa mempertimbangkan konsekuensi di masa mendatang [18].

1. Representasi Matematis

Misalkan terdapat himpunan titik yang akan dikunjungi $V = \{v_1, v_2, \dots, v_n\}$ dan matriks jarak D dengan elemen d_{ij} yang menyatakan jarak antara titik v_i dan v_j . Jarak antar titik yang berupa koordinat geografis (lintang dan bujur) dihitung menggunakan rumus Haversine [12].

$$d_{ij} = 2R \cdot \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta lat}{2} \right) + \cos(lat_i) \cdot \cos(lat_j) \cdot \sin^2 \left(\frac{\Delta lon}{2} \right)} \right) \quad (2.11)$$

Dengan:

d = jarak antara dua titik (dalam kilometer)

R = jari-jari bumi (6.371 km)

$lat1, lon1$ = koordinat titik pertama

$lat2, lon2$ = koordinat titik kedua

2. Algoritma

Algoritma Nearest Neighbor untuk menyusun rute dengan titik awal s (dalam konteks ini adalah hotel) dapat dinyatakan sebagai berikut [6]:

1. Inisialisasi himpunan titik yang belum dikunjungi $U = V \setminus \{s\}$
2. Inisialisasi rute $R = [s]$
3. Tetapkan titik saat ini $c = s$
4. Selama $U \neq \emptyset$:

$$c_{next} = \arg \min_{u \in U} d(c, u) \quad (2.12)$$

$$R = R + [c_{next}]$$

$$U = U \setminus \{c_{next}\}$$

$$c = c_{next}$$

5. Hasil akhir rute R adalah urutan kunjungan dari titik awal hingga semua titik terakhir.

3. Perhitungan Total Jarak

Total jarak tempuh untuk suatu rute $R = [v_1, v_2, \dots, v_n]$ dengan v_1 adalah titik awal dihitung dengan [6]:

$$Total\ Jarak = \sum_{k=1}^{n-1} d(v_k, v_{k+1}) \quad (2.13)$$

Dalam konteks perjalanan wisata, wisatawan umumnya tidak perlu kembali ke hotel setelah kunjungan terakhir di hari tersebut, sehingga digunakan rumus pertama [18].

2.2.7.3 Penerapan dalam Penyusunan Rute Harian

Misalkan terdapat himpunan titik yang akan dikunjungi $V = \{v_1, v_2, \dots, v_n\}$ dan matriks jarak D dengan elemen d_{ij} yang menyatakan jarak antara titik v_i dan v_j . Jarak antar titik yang berupa koordinat geografis (lintang dan bujur) dihitung menggunakan rumus Haversine [12]:

1. Titik awal: Hotel atau tempat menginap wisatawan menjadi titik awal perjalanan [6].
2. Daftar destinasi: POI yang telah dipilih pengguna untuk satu hari tertentu menjadi himpunan titik yang harus dikunjungi [9].
3. Perhitungan jarak: Jarak antar titik dihitung menggunakan rumus Haversine yang mempertimbangkan kelengkungan bumi [12].
4. Penyusunan rute: Algoritma NN menyusun urutan kunjungan dengan selalu memilih destinasi terdekat yang belum dikunjungi [6].
5. Perhitungan total jarak: Setelah rute diperoleh, total jarak tempuh untuk hari tersebut dihitung menggunakan rumus yang telah disebutkan [18].

BAB III


RANCANGAN DAN PEMBUATAN

3.1 Rancangan Sistem

Rancangan sistem dalam penelitian ini adalah sebuah aplikasi berbasis *web* yang menyediakan sistem perencanaan perjalanan wisata yang dibangun dengan penerapan metode pra-pemrosesan data semantik dan analisis data geospasial. Rancangan aplikasi ini berfungsi sebagai media interaktif bagi wisatawan dalam melakukan penyusunan rencana perjalanan wisata dengan preferensi yang diinginkan, kemudian menghasilkan rekomendasi rute perjalanan harian atau dapat disebut juga dengan istilah '*itinerary*' yang terstruktur. Proses utama dalam sistem ini melibatkan pencarian destinasi wisata yang relevan dengan preferensi wisatawan secara semantik dengan menggunakan metode Retrieval-Augmented Generation (RAG), dilanjutkan dengan pengelompokan lokasi destinasi berdasarkan kedekatan geografis (lintang dan bujur) menggunakan algoritma Intelligent K-Means.

Dengan rancangan sistem ini, wisatawan dapat menyusun rencana perjalanan wisatawan secara efisien. Wisatawan dapat dengan mudah mendapatkan destinasi wisata yang personal dan memilih sesuai dengan karakteristik yang diinginkan. Kemudian destinasi-destinasi yang terpilih akan dioptimalkan urutan kunjungannya menggunakan algoritma Greedy Nearest Neighbor. Sistem pada aplikasi ini dirancang untuk dapat memberikan rekomendasi

destinasi sesuai preferensi dan pertimbangan dalam aspek efisiensi pergerakan secara spasial. Dengan demikian, sistem ini diharapkan dapat memberikan pengalaman perencanaan wisata dengan memaksimalkan potensi perjalanan yang dilakukan. Arsitektur umum dari rancangan sistem dapat dilihat pada Gambar 3.1.



Gambar 3. 1 Diagram Alur Sistem

3.1.1 Tahap Perencanaan

Tahap perencanaan menjadi Langkah awal yang penting dalam pengembangan sistem yang menitikberatkan pada identifikasi kebutuhan serta alasan mendasar untuk membangun sistem perencanaan perjalanan wisata. Dalam konteks pariwisata dengan tujuan perjalanan di DKI Jakarta, wisatawan sering kali mengalami kesulitan dalam menyusun rencana perjalanan yang sesuai dengan preferensi mereka secara efisien, kemudian adanya pertimbangan lainnya

seperti ketersediaan fasilitas umum seperti restoran dan minimarket, serta kompleksitas rute yang harus ditempuh.

Sebagian wisatawan biasanya menyusun perjalanan wisata dan mencari destinasi dengan berbagai pertimbangan, sehingga menjadi sebuah tantangan bagi wisatawan yang harus menghabiskan banyak waktu dalam menyusun rencana perjalanan wisata. Oleh karena itu, penelitian ini merancang sebuah sistem yang dapat mengintegrasikan metode RAG untuk menangkap preferensi wisatawan secara semantik dan Intelligent K-Means untuk mengelompokkan destinasi berdasarkan preferensi dan spasial. Beberapa alasan utama dilakukannya perencaan sistem ini antara lain:

1. Kebutuhan personalisasi perjalanan wisata yang dapat menyesuaikan dengan preferensi pengguna secara semantik dari masukkan teks bebas yang menyangkut dengan keinginan wisatawan terhadap destinasi yang akan direkomendasikan dengan pencarian secara semantik.
2. Wisatawan dapat menyusun rencana perjalanan wisata secara efisien dengan memilih destinasi yang telah dikelompokkan dan diinterpretasi (misalnya ada 2 kelompok yaitu kelompok destinasi yang cukup dekat dengan hotel dan aksesibilitas transportasi yang cukup memadai atau kelompok destinasi yang sangat dekat dengan hotel dan aksesibilitas fasilitas pendukung yang memadai).
3. Pemanfaatan data geografis dan tekstual dari sumber terbuka seperti OpenStreetMap (OSM), data transportasi umum GTFS, dan panduan wisata,

sehingga sistem dapat menyediakan rute perjalanan yang praktis dan terintegrasi dengan opsi transportasi publik.

Dengan perencanaan ini, rancangan sistem yang dibuat dapat membantu wisatawan dalam menyusun rencana perjalanan dengan efisien karena destinasi telah dikelompokkan sesuai karakteristik masing-masing dan hasil pemilihan destinasi diberikan solusi rute yang optimal. Tahapan perencanaan tersebut dituangkan secara sistematis dalam diagram alur sistem yang dapat dilihat pada gambar 3.1.

3.1.2 Tahap Analisis

Tahap analisis adalah langkah penting untuk mengidentifikasi kebutuhan teknis dan perangkat yang digunakan agar sistem perencanaan perjalanan wisata dapat berjalan optimal dan sesuai dengan rancangan yang telah dibuat. Pada tahap ini, dilakukan analisis terhadap perangkat keras (*hardware*) dan perangkat lunak (*software*) yang diperlukan dalam pengembangan sistem rekomendasi perencanaan perjalanan berbasis RAG dan Intelligent K-Means. Analisis ini bertujuan untuk memastikan sistem dapat berjalan secara optimal sesuai dengan kapasitas perangkat yang tersedia dan mendukung seluruh proses mulai dari akuisisi data, pemrosesan, hingga visualisasi hasil.

3.1.2.1 Perangkat Keras

Pada penelitian ini, perangkat keras yang digunakan yaitu laptop ASUS TUF Gaming F15 dengan spesifikasi sebagai berikut:

1. Model: ASUS TUF Gaming F15 FX506LH_FX506LH

2. Prosesor: Intel(R) Core(TM) i7-10870H @ 2.20GHz (16 CPUs), ~2.2GHz
3. Memori (RAM): 16 GB
4. Penyimpanan: SSD 512 GB
5. GPU: NVIDIA® GeForce GTX™ 1650, 4GB GDDR5,

Pemilihan laptop dengan prosesor Intel Core i7 generasi ke-10 dan RAM 16 GB memberikan keuntungan dalam menjalankan proses komputasi yang cukup berat, seperti pembuatan embedding dari model bahasa besar (LLM) menggunakan Ollama, perhitungan jarak geografis untuk ratusan POI, serta iterasi algoritma *clustering* Intelligent K-Means. Kapasitas memori yang memadai juga memastikan bahwa data spasial dan tekstual dapat diproses tanpa mengalami keterbatasan memori. Penggunaan SSD mempercepat akses data dari file CSV dan proses *loading* dataset, sehingga waktu eksekusi keseluruhan menjadi lebih efisien.



Gambar 3. 2 Spesifikasi Laptop

3.1.2.2 Perangkat Lunak

Perangkat Lunak yang digunakan dalam penelitian ini terdiri dari beberapa lapisan, mulai dari sistem operasi, bahasa pemrograman, pustaka analisis, hingga *framework* untuk pengembangan aplikasi. Untuk detail penjelasan adalah sebagai berikut:

1. Sistem Operasi

Windows 11 sebagai sistem operasi utama laptop pengembangan. Lingkungan Windows dipilih karena kemudahan dalam menjalankan berbagai aplikasi pendukung dan kompatibilitas dengan pustaka Python yang digunakan.

2. Bahasa Pemrograman

Python merupakan Bahasa pemrograman utama yang digunakan untuk keseluruhan proses pengolahan data, pembuatan *embedding*, perhitungan jarak, *clustering*, dan pengembangan *backend* API. Python dipilih karena ketersediaan pustaka yang kaya dan cocok untuk analisis data, *machine learning*, dan komputasi numerik.

3. Pustaka (*Library*)

Pustaka (*library* Python) yang digunakan berdasarkan keperluan analisis dan pengolahan data terdiri dari: manipulasi dan analisis data numerik (*pandas*, *numpy*), pencocokan entitas secara *fuzzy* antara data buku panduan dan OSM, ekstraksi teks dari dokumen PDF buku panduan wisata (*pdfplumber*), dan model *embedding* (*ollama*).

4. Basis Data

PostgreSQL dipilih sebagai sistem manajemen basis data utama karena kehandalannya dalam menangani data terstruktur dalam jumlah besar. Data yang dikelola meliputi data POI dari OpenStreetMap, data GTFS, data hasil ekstraksi buku panduan, serta data hasil perhitungan fitur. PostgreSQL berperan sebagai penyimpanan terpusat yang menjamin konsistensi data.

5. *Backend Framework*

FastAPI dipilih sebagai *framework* backend karena keunggulannya dalam membangun API yang cepat, modern, dan mudah diintegrasikan dengan pustaka *machine learning* Python. Backend bertanggung jawab atas penyediaan REST API untuk menerima input pengguna, menjalankan proses

embedding dan semantic search, menghitung fitur geospasial, melakukan clustering, menyusun rute harian, serta mengembalikan hasil rekomendasi dalam format JSON.

6. *Frontend Framework*

React dipilih sebagai *framework frontend* karena pendekatannya yang berbasis komponen, ekosistem yang kaya, serta kemampuannya membangun antarmuka yang interaktif dan responsif. React memudahkan pengembangan antarmuka yang kompleks dengan komponen yang dapat digunakan kembali. Komunikasi dengan *backend* FastAPI dilakukan melalui HTTP request menggunakan pustaka Axios. Selain itu React memiliki pustaka pendukung seperti react-leaflet yang dapat menampilkan visualisasi peta interaktif.

7. *Model Embedding dan Platform AI*

Ollama digunakan sebagai platform untuk menjalankan model *embedding*. Model embedding yang digunakan adalah 'nomic-embed-text', yang merupakan model ringan dengan performa baik untuk teks umum dan mendukung berbagai bahasa. Model ini menghasilkan vektor berdimensi 768 dan dapat dijalankan pada CPU dengan sumber daya yang memadai. Model generatif llama3 juga dijalankan melalui Ollama untuk menghasilkan deskripsi naratif dan ringkasan perjalanan.

8. *Alat Bantu Pengembangan (IDE)*

Ada dua alat dalam penelitian ini, yaitu Visual Studio Code untuk merancang kode program aplikasi dan Google Colab untuk pengujian dan eksekusi kode dengan tujuan eksperimen dengan data sampel.

3.1.2.3 Ringkasan Kebutuhan Perangkat Keras dan Lunak

Pada tabel 3.1 menyajikan ringkasan kebutuhan perangkat keras dan lunak yang digunakan dalam penelitian ini.

Tabel 3. 1 Ringkasan Kebutuhan Analisis Penggunaan Perangkat

Kategori	Spesifikasi / Teknologi	Keterangan
Perangkat Keras	Laptop ASUS TUF Gaming F15 FX506LH_FX506LH	Perangkat utama untuk pengembangan dan pengujian sistem
	Prosesor: Intel Core i7-10870H (16 CPU)	Mendukung komputasi parallel dan pemrosesan data intensif
	RAM: 16 GB	Memadai untuk menjalankan model <i>embedding</i> dan komputasi <i>machine learning</i> .
	Penyimpanan: 512 SSD	Akses data cepat dan <i>loading</i> dataset yang efisien

Sistem Operasi	Windows 11	Lingkungan pengembangan utama.
Basis Data	PostgreSQL	Penyimpanan data POI, GTFS, dan hasil perhitungan fitur
Bahasa Pemrograman	Python	Bahasa utama untuk pemrosesan data dan backend
	JavaScript	Bahasa untuk pengembangan frontend
<i>Backend Framework</i>	Fast API	REST API untuk komunikasi dengan frontend
<i>Frontend Framework</i>	React	Pengembangan antarmuka pengguna interaktif
Model AI (dari <i>platform</i> Ollama)	nomic-embed-text	Model embedding untuk pencarian semantik

	Llama3	Model generatif untuk deskripsi dan ringkasan
Pustaka Pendukung	Pandas, numpy, thefuzz, pdfplumber	Pemrosesan data, <i>clustering</i> , dan perhitungan jarak.
	react-leaflet	Visualisasi peta
Alat Bantu	Visual Studio Code, Google Colab	Pengembangan dan eksperimen

3.1.3 Tahap Perancangan


Pada tahap perancangan, dibuat rancangan awal sistem yang meliputi struktur data, alur proses, hingga tampilan antarmuka. Rancangan ini bertujuan untuk memastikan bahwa sistem rekomendasi rencana perjalanan wisata yang dibangun sesuai dengan kebutuhan analisis operasional yang telah diidentifikasi pada tahap sebelumnya. Komponen rancangan yang dibuat terdiri dari:

3.1.3.1 Diagram Arsitektur Sistem

Diagram arsitektur sistem menjelaskan alur data mulai dari sumber data, proses pra-pemrosesan, analisis RAG dan Intelligent K-Means, hingga visualisasi hasil pada antarmuka pengguna. Arsitektur sistem dirancang secara modular dengan pemisahan yang jelas antara *backend* (FastAPI) dan *frontend* (React), serta menggunakan basis data PostgreSQL sebagai basis data utama. Berikut adalah komponen utama dalam arsitektur sistem:

1. Lapisan Data: Terdiri dari tiga sumber data utama, yaitu OpenStreetMap (OSM), GTFS (General Transit Feed Specification), dan buku panduan wisata dalam format PDF. Data dari ketiga sumber ini diintegrasikan dan disimpan dalam PostgreSQL.
2. Lapisan *Backend* (FastAPI): Bertanggung jawab atas seluruh logika pemrosesan, meliputi pencarian semantic dengan model *embedding* (nomic-embed-text dari Ollama), perhitungan fitur geospasial (jarak ke hotel, aksesibilitas transportasi umum, dan fasilitas pendukung yang terdiri dari minimarket dan restoran), pengelompokkan dengan Intelligent K-Means, dan penyusunan rute harian dengan algoritma Greedy Nearest Neighbor.
3. Lapisan Frontend (React) : Menyediakan antarmuka pengguna yang interaktif, terdiri dari tiga halaman utama, yaitu halaman *input* (lokasi untuk *filtering*, hari, dan preferensi pengguna mengenai destinasi wisata), halaman pemilihan *cluster* destinasi, dan halaman hasil rekomendasi dengan visualisasi peta.
4. Lapisan Basis Data: PostgreSQL menyimpan data POI enriched, data GTFS, dan data hasil perhitungan fitur.

Untuk memperjelas setiap lapisan arsitektur sistem, dapat dilihat pada Gambar 3.3 yang ada di bawah ini.



Gambar 3. 3 Arsitektur Sistem

3.1.3.2 Data Flow Diagram (DFD)

Data Flow Diagram (DFD) digunakan untuk memberi gambaran aliran data dalam sistem perencanaan perjalanan, mulai dari sumber data, proses pengelolaan data, hingga keluaran informasi yang dihasilkan. DFD membantu menjelaskan bagaimana data mengalir antar entitas eksternal, proses sistem, serta media penyimpanan data secara terstruktur dan mudah dipahami.

Dalam rancangan ini, DFD disusun secara bertahap, dimulai dari DFD level 0 (*Context Diagram*) untuk memberikan gambaran umum interaksi antara sistem dengan entitas eksternal, kemudian dilanjutkan dengan DFD level 1 dan level 2 untuk menjelaskan proses sistem secara lebih rinci.


1. DFD Level 0 (*Context Diagram*)

DFD Level 0 menggunakan sistem sebagai satu kesatuan proses tunggal yang berinteraksi dengan entitas eksternal. Pada sistem ini, entitas eksternal yang terlibat adalah pengguna dan *admin*. Diagram ini menunjukkan gambaran aliran data antara entitas dan sistem.



Gambar 3. 4 DFD Level 0 (Context Diagram)

2. DFD Level 1



Gambar 3. 5 DFD Level 1 (Proses Utama)

DFD Level 1 menguraikan sistem menjadi proses-proses utama yang lebih detail. Berikut adalah proses-proses utama dalam sistem:

1. Proses 1 (Pengelolaan Data Master)

Mengelola data dari OSM, GTFS, dan buku panduan.

2. Proses 2 (Pencarian Semantik (RAG))

Melakukan *embedding* dan perhitungan dengan metode *cosine similarity*.

3. Proses 3 (Perhitungan Fitur Geospasial)

Menghitung jarak, aksesibilitas, dan fasilitas.

4. Proses 4 (*Clustering* Intelligent K-Means)

Mengelompokkan POI (destinasi wisata) berdasarkan fitur.

5. Proses 5 (Optimasi Rute)


Menyusun rute harian dengan algoritma Greedy Nearest Neighbor.

6. Proses 6 (Antarmuka Pengguna)

Menangani interaksi dengan pengguna.

3. DFD Level 2 (Pencarian Semantik)


Untuk memberikan detail tambahan, berikut adalah DFD Level 2 untuk proses 2 (Pencarian Semantik) yang menunjukkan aliran data internal dalam sub-sistem RAG.



Gambar 3. 6 DFD Level 2 (Pencarian Semantik)

4. DFD Level 2 (Clustering Intelligent K-Means)

Berikut adalah DFD Level 2 untuk Proses 4 yang menunjukkan detail aliran data dalam sub-sistem clustering.



Gambar 3. 7 DFD Level 2 (Intelligent K-Means Clustering)

Dengan adanya DFD bertingkat ini, diharapkan alur pemrosesan data pada sistem rekomendasi rencana perjalanan wisata dapat dipahami secara jelas dan sistematis, mulai dari sumber data hingga keluaran yang disajikan kepada pengguna.

3.2 Pembuatan Sistem

Tahap pembuatan sistem ini merupakan bagian dari implementasi dari rancangan yang telah dibuat melalui serangkaian proses sistematis dan terstruktur. Proses ini mencakup pengumpulan data dari sumber data, pra-pemrosesan data untuk memastikan kualitas dan konsistensi, analisis mendalam

menggunakan metode *Retrieval-Augmented Generation* (RAG) dan Intelligent K-Means *Clustering*, hingga integrasi hasil analisis ke dalam antarmuka *web* yang interaktif. Setiap tahapan dikerjakan dengan memastikan bahwa data yang diolah relevan untuk kebutuhan rekomendasi perjalanan. Hasil dari proses ini adalah sebuah sistem pengelompokan destinasi wisata yang dapat disusun secara komprehensif berdasarkan kelasnya (kelompok *cluster*), yang tidak hanya menampilkan visualisasi peta dan daftar destinasi, tetapi juga memberikan rekomendasi yang dapat digunakan oleh wisatawan dalam merencanakan perjalanan wisata. Selain itu destinasi-destinasi yang dipilih juga akan dioptimalisasi dengan Intelligent K-Means.

3.2.1 Skema Pengumpulan Data

Tahap pengumpulan data dilakukan dengan memanfaatkan data dari tiga sumber utama yang telah diidentifikasi pada tahap perancangan: OpenStreetMap (OSM) , General Transit Feed Specification (GTFS) , dan buku panduan wisata dalam format PDF. Data dari ketiga sumber ini dikumpulkan melalui proses ekspor atau unduhan dari penyedia data, sehingga mencerminkan kondisi nyata dari destinasi wisata, fasilitas pendukung, dan aksesibilitas transportasi di Jakarta. Adapun data yang dikumpulkan mencakup atribut-atribut utama, antara lain nama destinasi, koordinat geografis, kategori, subkategori, deskripsi, alamat, informasi kontak, serta data halte. Data tersebut menjadi fondasi dalam pembentukan fitur-fitur yang akan digunakan dalam proses clustering dan rekomendasi. Skema tahapan utama pengumpulan data tertera pada Gambar 3.2.

museum, restaurant, monument, dan lain-lain), koordinat geografis (*lat, lon*), dan *raw_tags* (metadata tag OSM dalam format JSON dengan menggabungkan data nama destinasi, kategori, sub kategori, *cuisine, website*, dan data tambahan lain yang memiliki data kosong di sebagian besar POI).

2. Pengumpulan Data GTFS

Data GTFS diperoleh dari Mobility Database [24] untuk layanan Transjakarta. Data ini mencakup informasi rute halte di Jakarta. File yang diunduh dalam format ZIP kemudian diekstrak untuk mendapatkan file-file yang terdiri dari daftar halter dengan koordinat (*stop.txt*) dan data jadwal kedatangan. Data ini dibaca menggunakan pustaka *pandas* dan disimpan dalam basis data PostgreSQL untuk memudahkan penggabungan dengan data POI.

3. Data Buku Panduan PDF

Buku panduan wisata dalam format PDF diekstraksi menggunakan pustaka *pdfplumber*. Sumber data yang digunakan yaitu "*The Official Jakarta Tourism Guidebook*" [25] Proses ekstraksi dilakukan dengan pendekatan berbasis pola untuk mengidentifikasi entitas POI, karena setiap buku panduan memiliki format yang berbeda. Untuk buku panduan Jakarta yang terstruktur, digunakan pendekatan deteksi nomor urut POI. Dari 140 entri buku panduan Jakarta, sebanyak 120 POI berhasil dicocokkan dengan data OSM, sementara 20 POI lainnya tidak ditemukan kecocokan dan ditambahkan sebagai entri baru dengan koordinat dari hasil geocoding alamat menggunakan *Nominatim*. Hasil penggabungan ini menghasilkan data POI yang diperkaya dengan informasi

deskriptif dari buku panduan dan data spasial dari OSM. Data yang diperkaya menghasilkan struktur dengan kolom-kolom utama sebagai berikut:

1. name: nama destinasi
 2. category: kategori utama (tourism, amenity, historic, dll.)
 3. subcategory: subkategori (museum, monument, restaurant, dll.)
 4. lat, lon: koordinat geografis
 5. description: deskripsi dari buku panduan
 6. phone, website, social_media: informasi kontak
 7. district, province: informasi administratif
4. Seluruh data yang telah dikumpulkan dan diproses disimpan ke dalam basis data PostgreSQL untuk memudahkan pengelolaan dan akses oleh backend. Skema tabel yang digunakan terdiri dari tabel data POI dari OSM (*osm_poi*), tabel data POI dari buku panduan (*guidebook_poi*), tabel data POI hasil integrasi gabungan OSM dan buku panduan (*poi_enriched*), tabel data koordinat halte dari GTFS (*stops*), dan tabel jadwal kedatangan dari GTFS (*stop_times*).

Dengan demikian, seluruh data yang diperlukan untuk sistem perencanaan perjalanan wisata telah terkumpul dan tersimpan secara terstruktur dalam basis data PostgreSQL, siap untuk digunakan pada tahap pra-pemrosesan dan analisis selanjutnya.

3.2.2 Skema Pra-pemrosesan dan Integrasi Data

Tahap pra-pemrosesan dan integrasi data merupakan langkah untuk memastikan bahwa data dari berbagai sumber yang telah dikumpulkan dapat digunakan untuk analisis. Data dari OpenStreetMap (OSM), GTFS, dan buku panduan PDF memiliki format, struktur, dan tingkat kelengkapan yang berbeda. Oleh karena itu, diperlukan serangkaian proses untuk membersihkan, menstandarisasi, menggabungkan, dan memperkaya data sehingga menghasilkan basis data POI yang terintegrasi dan siap digunakan untuk pencarian semantik, perhitungan fitur, dan *clustering*. Tahap-tahap pra-pemrosesan ini dilakukann secara bertahap dan sistematis.

1. Pembersihan Data OSM

Data POI dari OpenStreetMap yang telah diekstraksi masih mengandung sejumlah masalah seperti duplikasi, nilai kosong pada atribut penting (misalnya nama), serta koordinat yang berada di luar wilayah Jakarta. Oleh karena itu, dilakukan pembersihan dengan menghapus baris yang tidak memiliki nama, menghilangkan duplikasi berdasarkan nama_destinasi, serta memfilter koordinat agar hanya mencakup wilayah DKI Jakarta. Selain itu, kategori dan subkategori distandarisasi menjadi huruf kecil untuk memudahkan pencocokan nantinya.

2. Pembersihan Data GTFS

Data GTFS yang terdiri dari file stops.txt juga perlu dibersihkan. Halte dengan koordinat tidak valid (kosong) dihapus karena tidak dapat digunakan dalam perhitungan jarak. Data dengan waktu yang tidak wajar juga dieliminasi.

3. Pembersihan Data Buku Panduan

Data hasil ekstraksi dari PDF buku panduan wisata seringkali mengandung karakter tidak diinginkan, spasi berlebih, atau teks yang terpotong. Oleh karena itu, dilakukan pembersihan teks dengan menghapus karakter khusus, menormalkan spasi, dan memastikan konsistensi format. Data dari beberapa dokumen digabungkan menjadi satu kumpulan, lalu duplikasi berdasarkan nama destinasi dihilangkan.

4. Pencocokan Entitas dengan *Fuzzy Matching*

Langkah paling kritis adalah mencocokkan POI dari buku panduan dengan data OSM. Karena perbedaan ejaan, singkatan, atau urutan kata, digunakan metode fuzzy matching dengan algoritma token_sort_ratio yang mengabaikan urutan kata. Setiap nama POI dari buku panduan dibandingkan dengan daftar nama OSM, dan jika skor kemiripan mencapai ambang batas tertentu (batas yang ditetapkan 75%), maka kedua entitas dianggap sama. Data OSM (koordinat, kategori, dan sebagainya.) kemudian digabungkan dengan data deskriptif dari buku panduan. POI yang berhasil dicocokkan diberi label sumber pdf+osm.

5. Geocoding untuk POI yang Tidak Cocok

POI dari buku panduan yang tidak berhasil dicocokkan dengan OSM tetap dapat digunakan jika memiliki alamat yang jelas. Untuk itu, dilakukan *geocoding* menggunakan layanan Nominatim untuk memperkirakan koordinat berdasarkan alamat. Proses ini dilakukan dengan jeda antar permintaan untuk menghormati batasan penggunaan. POI yang berhasil di-*geocode* kemudian ditambahkan ke dalam kumpulan data dengan label sumber *pdf_only*. Jika alamat tidak dapat di-*geocode*, POI tersebut tidak disertakan.

6. Penggabungan Data POI Enriched

Setelah pencocokan dan geocoding, semua data dari OSM, hasil fuzzy matching, dan hasil geocoding digabungkan menjadi satu tabel utama yang disebut *poi_enriched*. Tabel ini berisi informasi lengkap setiap POI, seperti nama, kategori, subkategori, koordinat, deskripsi, kontak, serta sumber data. Duplikasi berdasarkan nama dan koordinat dihapus untuk menjaga konsistensi.

7. Klasifikasi Fasilitas Pendukung

Untuk keperluan analisis ketersediaan fasilitas di sekitar POI, data OSM yang telah dibersihkan diklasifikasikan ke dalam tiga kategori: restoran dan minimarket. Restoran diidentifikasi melalui *tag amenity=restaurant, cafe, fast_food*. Minimarket diidentifikasi melalui *tag shop=convenience* atau nama yang mengandung merek seperti Indomaret, Alfamart, Circle K, dan Family Mart. Klasifikasi ini menghasilkan

tiga himpunan titik yang akan digunakan dalam perhitungan jumlah fasilitas dalam radius tertentu.

8. Perhitungan Kedekatan dengan Halte Transportasi

Sebagai indikator aksesibilitas transportasi umum, sistem hanya menggunakan jarak setiap POI ke halte terdekat. Data halte dari GTFS yang telah dibersihkan digunakan untuk menghitung jarak geografis antara setiap POI dan semua halte. Jarak terpendek kemudian dipilih sebagai nilai kedekatan. Semakin kecil jarak ke halte, semakin baik aksesibilitas transportasi umum bagi destinasi tersebut. Informasi ini akan menjadi salah satu fitur dalam proses clustering.

9. Normalisasi dan Standarisasi Format


Sebelum penyimpanan akhir ke basis data, semua kolom distandarisasi namanya (misalnya lat menjadi latitude, lon menjadi longitude). Nilai kosong diisi dengan NULL atau nilai default yang sesuai, dan indeks direset untuk menghindari masalah dalam pengolahan berikutnya.

10. Menyimpan data ke basis data (PostgreSQL)

Data yang telah terintegrasi dan kaya informasi disimpan ke dalam basis data PostgreSQL. Tabel-tabel yang dibuat meliputi data utama POI (*poi_enriched*), titik-titik restoran, titik-titik minimarket, dan data halte yang telah dibersihkan.

Dengan penyimpanan ini, seluruh data siap diakses oleh backend untuk proses selanjutnya, seperti pencarian semantik, perhitungan fitur, dan clustering.

Skema integrasi data secara ringkas dapat dilihat pada Gambar 3.12 yang memperlihatkan aliran data dari ketiga sumber hingga menjadi data POI enriched yang tersimpan di PostgreSQL.



Gambar 3. 9 Skema Pengumpulan Data

3.2.3 Skema Pembuatan *Embedding* dan Pencarian Semantik (RAG)

Setelah data POI terintegrasi dan tersimpan dalam basis data, tahap selanjutnya adalah membangun komponen *Retrieval-Augmented Generation* (RAG) yang bertugas memahami preferensi pengguna secara semantik. Proses ini mengubah teks preferensi pengguna dan teks representasi

destinasi (nama destinasi, kategori, sub kategori, dan deskripsi POI) menjadi vektor numerik (*embedding*), kemudian menghitung tingkat kemiripan antara keduanya. Hasilnya adalah skor relevansi yang menunjukkan seberapa cocok suatu destinasi dengan keinginan pengguna. Skor ini akan menjadi salah satu fitur penting dalam proses *clustering*.

1. Representasi teks POI

Setiap POI dalam basis data perlu direpresentasikan dalam bentuk teks yang kaya informasi agar dapat di-*embed* dengan baik. Representasi ini menggabungkan beberapa atribut penting dari POI, yaitu nama, kategori, subkategori, dan deskripsi. Format representasi yang digunakan yaitu nama POI, kategori, sub kategori, dan deskripsi. Pemilihan format ini didasarkan pada pertimbangan bahwa model *embedding* bekerja lebih baik jika teks memiliki struktur yang jelas dan memisahkan setiap komponen informasi. Kategori dan subkategori membantu model memahami jenis destinasi, sementara deskripsi memberikan konteks yang lebih mendalam tentang daya tarik dan fasilitas yang tersedia. Untuk POI yang tidak memiliki deskripsi, bagian deskripsi dikosongkan.

2. Model *Embedding*

Model *embedding* yang digunakan dalam sistem ini adalah “*nomic-embed-text*” yang dijalankan melalui platform Ollama. Model ini dipilih karena ringan dan efisien (dimensi 768), model yang cukup ringan, tetapi mampu menangkap

makna semantik cukup baik, kemudian mendukung multibahasa, serta mudah diintegrasikan tanpa perlu infrastruktur rumit.

3. Proses *Embedding* POI

Sebelum sistem dapat melakukan pencarian, semua POI dalam basis data harus melalui proses *embedding* terlebih dahulu. Proses ini dilakukan satu kali secara *batch* dan hasilnya disimpan untuk digunakan berulang kali. Pertama, untuk setiap POI dalam basis data, dibangun teks representasi sesuai format yang telah ditentukan. Kemudian teks representasi tersebut dikirim ke Ollama untuk diubah menjadi vektor *embedding* berdimensi 768. Vektor yang dihasilkan disimpan dalam basis data, baik sebagai kolom terpisah maupun dalam basis data vektor (ChromaDB) untuk memudahkan pencarian. Proses ini dilakukan secara bertahap untuk menghindari beban berlebih pada system.

4. *Embedding* Input Pengguna (Preferensi)

Ketika pengguna memasukkan preferensi dalam bentuk teks bebas (misalnya "saya suka tempat bersejarah yang tenang dan dekat dengan museum"), sistem akan menerima teks preferensi dari yang dimasukkan pengguna, kemudian membersihkan teks dari karakter tidak perlu dan mengubahnya menjadi huruf kecil untuk konsistensi. Setelah itu teks disalurkan ke Ollama dengan model "nomic-embed-text" untuk menghasilkan vektor *embedding*. Terakhir, Vektor yang dihasilkan memiliki dimensi yang sama dengan vektor POI, sehingga dapat dibandingkan.

5. Perhitungan *Cosine Similarity*

Setelah vektor preferensi pengguna diperoleh, sistem menghitung tingkat kemiripan antara vektor tersebut dengan seluruh vektor POI yang telah tersimpan. Metode yang digunakan adalah cosine similarity, yang mengukur sudut antara dua vektor dalam ruang multidimensi. Nilai cosine similarity berkisar antara -1 hingga 1, di mana nilai mendekati 1 menunjukkan kemiripan semantik yang tinggi.

6. Pemilihan kandidat POI (Top-K)


Setelah nilai cosine similarity dihitung, sistem mengurutkan POI berdasarkan nilai similarity tertinggi. Sejumlah top-K POI (misalnya dibatasi 50 atau 100 destinasi atau POI) dipilih sebagai kandidat untuk diproses lebih lanjut. Pemilihan nilai K mempertimbangkan keseimbangan antara kualitas rekomendasi dan beban komputasi pada tahap *clustering*. Semakin besar K, semakin banyak POI yang dipertimbangkan, namun juga semakin berat perhitungan.

7. Penyimpanan sementara hasil pencarian.

Hasil pencarian (daftar POI kandidat dan skor relevansi) disimpan sementara dalam memori atau dalam basis data sesi untuk digunakan pada tahap berikutnya. Hal ini memungkinkan pengguna untuk melakukan iterasi (misalnya mengubah preferensi) tanpa perlu mengulang seluruh proses *embedding* dari awal.

8. Diagram alur Semantic Search

Untuk memudahkan pemahaman, Gambar 3.13 memperlihatkan alur proses *semantic search* mulai dari input preferensi pengguna hingga diperolehnya daftar POI kandidat beserta skor relevansi.



Gambar 3. 10 Proses Pencarian Semantik RAG

9. Integrasi dengan modul lain

Hasil dari proses *semantic search* (daftar POI kandidat dan skor relevansi) menjadi masukan utama bagi modul perhitungan fitur geospasial. Pada modul tersebut, setiap POI kandidat akan dilengkapi dengan informasi tambahan seperti jarak ke hotel, jarak ke halte terdekat, serta jumlah fasilitas pendukung di sekitarnya. Setelah semua fitur terkumpul, barulah dilakukan proses *clustering* dengan algoritma Intelligent K-Means.

3.2.4 Skema Perhitungan Fitur Spasial untuk *Clustering*

Setelah mendapatkan daftar POI kandidat dari proses pencarian semantik, langkah selanjutnya adalah menghitung fitur-fitur yang akan digunakan dalam proses *clustering*. Fitur-fitur ini merepresentasikan berbagai aspek penting dari setiap destinasi, meliputi aspek spasial, aksesibilitas, ketersediaan fasilitas pendukung, serta tingkat relevansi dengan preferensi pengguna. Perhitungan fitur dilakukan secara sistematis untuk setiap POI kandidat, dan hasilnya akan membentuk matriks fitur yang menjadi masukan utama bagi algoritma Intelligent K-Means.

3.2.4.1 Jenis Fitur yang Digunakan

Dalam penelitian ini, terdapat lima kelompok fitur utama yang digunakan untuk mengelompokkan destinasi wisata:

1. Fitur spasial: Koordinat geografis (lintang dan bujur) yang merepresentasikan lokasi absolut setiap destinasi.
2. Fitur relevansi semantik: Skor hasil pencarian RAG yang menunjukkan tingkat kesesuaian destinasi dengan preferensi pengguna.
3. Fitur aksesibilitas: Jarak terdekat antara destinasi dengan halte transportasi umum.
4. Fitur jarak ke hotel: Jarak geografis antara destinasi dengan titik awal perjalanan (hotel).
5. Fitur fasilitas pendukung: Jumlah restoran, minimarket, dan fasilitas umum lainnya dalam radius tertentu dari destinasi.

Pemilihan fitur-fitur ini didasarkan pada pertimbangan bahwa wisatawan tidak hanya mempertimbangkan lokasi destinasi, tetapi juga kemudahan akses, ketersediaan fasilitas di sekitar, serta kesesuaian dengan preferensi wisatawan.

3.2.4.2 Perhitungan Jarak Destinasi Ke Hotel

Fitur ini mengukur seberapa jauh suatu destinasi dari tempat menginap wisatawan. Titik hotel ditentukan oleh pengguna pada saat memasukkan preferensi, baik dengan memilih pada peta maupun memasukkan koordinat secara manual. Perhitungan jarak dilakukan menggunakan rumus Haversine, yang mengukur jarak geografis antara dua titik di permukaan bumi dengan mempertimbangkan kelengkungan bumi. Hasil perhitungan dinyatakan dalam satuan meter. Semakin kecil nilai jarak ke hotel, semakin dekat destinasi tersebut dengan tempat menginap, yang berarti lebih efisien untuk dikunjungi, terutama pada hari pertama perjalanan.

3.2.4.3 Perhitungan Kedekatan dengan Halte Transportasi

Fitur aksesibilitas diukur dengan mencari jarak terdekat antara setiap POI kandidat dengan halte transportasi umum yang tersedia dalam data GTFS. Proses ini dilakukan dengan membandingkan koordinat POI dengan koordinat seluruh halte, lalu memilih jarak terpendek. Jarak yang dihasilkan dinyatakan dalam satuan meter. Semakin kecil jarak ke halte terdekat, semakin mudah destinasi tersebut dijangkau dengan transportasi umum. Hal ini menjadi pertimbangan penting bagi wisatawan yang tidak menggunakan kendaraan pribadi.

3.2.4.4 Perhitungan Jumlah Fasilitas Pendukung

Fasilitas pendukung meliputi restoran, kafe, dan minimarket yang berada di sekitar destinasi. Data fasilitas ini diperoleh dari OpenStreetMap yang telah diklasifikasikan sebelumnya. Perhitungan dilakukan dalam radius tertentu (misalnya 500 meter) dari setiap POI kandidat. Jumlah fasilitas dalam radius ini menjadi indikator kenyamanan dan kelengkapan layanan di sekitar destinasi. Destinasi dengan banyak fasilitas pendukung cenderung lebih diminati karena wisatawan dapat dengan mudah memenuhi kebutuhan selama berwisata.

3.2.4.5 Penggabungan Fitur

Setelah semua fitur dihitung untuk setiap POI kandidat, data tersebut digabungkan menjadi satu tabel yang berisi:

1. nama destinasi
2. koordinat geografis (lintang dan bujur)
3. skor relevansi (dari proses RAG)
4. jarak ke hotel (meter)
5. jarak ke halte terdekat (meter)
6. jumlah restoran dalam radius 500 meter.
7. jumlah minimarket dalam radius 500 meter.

Data-data pada atribut ini akan menjadi masukan untuk proses normalisasi dan *clustering*.

3.2.4.6 Normalisasi Fitur

Fitur-fitur yang telah dihitung memiliki satuan dan rentang nilai yang berbeda-beda. Misalnya, koordinat geografis memiliki rentang nilai yang sempit,

sementara jarak ke hotel bisa mencapai puluhan kilometer. Jika tidak dinormalisasi, fitur dengan rentang nilai besar akan mendominasi perhitungan jarak dalam *clustering*. Oleh karena itu, dilakukan normalisasi dengan tujuan untuk mengubah setiap fitur sehingga memiliki rata-rata 0 dan standar deviasi 1. Proses normalisasi dilakukan dengan menghitung nilai rata-rata dan standar deviasi untuk setiap fitur, lalu mentransformasi setiap nilai menggunakan rumus z-score (2,n). Hasil normalisasi adalah matriks fitur dengan skala yang seragam, siap untuk diproses oleh algoritma Intelligent K-Means.

3.2.4.7 Ringkasan Proses Perhitungan Fitur

Untuk memberikan gambaran yang lebih jelas, Tabel 3.2 menyajikan ringkasan fitur yang dihitung beserta sumber data dan metode perhitungannya.


Tabel 3. 2 Keterangan Fitur

No	Fitur	Sumber Data	Metode Perhitungan	Satuan
1	Koordinat lintang	OSM	Ekstraksi langsung	Derajat desimal
2	Koordinat Bujur	OSM	Ekstraksi langsung	Derajat desimal
3	Skor relevansi	RAG	Cosine Similarity	Nilai numerik tertinggi dari skor relevansi
4	Jarak ke hotel	Input Pengguna atau OSM	Haversine	Meter

5	Jarak ke halte terdekat	GTFS	Haversine	Meter
6	Jumlah restoran (500 meter)	OSM	Hitung jumlah titik dalam radius	Unit
7	Jumlah minimarket (500 meter)	OSM	Hitung jumlah titik dalam radius	Unit

3.2.4.8 Diagram Alir Perhitungan Fitur

Gambar 3.14 memperlihatkan alur proses perhitungan fitur untuk *clustering*, mulai dari data POI kandidat hingga diperoleh matriks fitur ternormalisasi yang siap digunakan.



Gambar 3. 11 Diagram Alir Perhitungan Fitur

Dengan selesainya tahap perhitungan fitur, sistem kini memiliki representasi numerik yang lengkap untuk setiap POI kandidat. Matriks fitur ternormalisasi inilah yang akan menjadi masukan utama bagi algoritma Intelligent K-Means pada tahap selanjutnya.

3.2.5 Skema Penentuan Jumlah *Cluster* Optimal

Setelah fitur-fitur untuk setiap POI kandidat dihitung dan dinormalisasi, langkah berikutnya adalah menentukan jumlah cluster yang paling sesuai untuk data tersebut. Penentuan jumlah cluster (nilai k) merupakan tahap kritis dalam algoritma K-Means, karena nilai k yang tidak tepat dapat menghasilkan pengelompokan yang kurang bermakna atau terlalu terpecah. Dalam sistem ini, penentuan jumlah cluster optimal dilakukan dengan menggabungkan dua metode evaluasi yang umum digunakan, yaitu metode Elbow dan Silhouette Score. Kedua metode ini saling melengkapi untuk memastikan bahwa jumlah cluster yang dipilih tidak hanya optimal secara statistik, tetapi juga dapat diinterpretasikan dengan baik dalam konteks perencanaan perjalanan.

3.2.6 Skema *Clustering* dengan Intelligent K-Means

Setelah semua fitur geospasial, aksesibilitas, fasilitas pendukung, dan skor relevansi semantik berhasil dihitung untuk setiap POI kandidat, langkah selanjutnya adalah melakukan pengelompokan (*clustering*) menggunakan algoritma *Intelligent K-Means*. Tujuan dari tahap ini adalah untuk membagi POI ke dalam beberapa kelompok (*cluster*) yang memiliki karakteristik serupa

berdasarkan fitur-fitur yang telah disiapkan. Hasil pengelompokan ini akan menjadi dasar bagi pengguna untuk memilih destinasi per hari perjalanan.

Data POI yang dikelompokkan terdiri dari tujuh fitur utama yang ada pada tabel 3.x. Fitur-fitur tersebut memiliki satuan dan rentang nilai yang berbeda, normalisasi menjadi langkah penting sebelum proses *clustering*. Metode normalisasi yang digunakan adalah StandardScaler, yang mengubah setiap fitur sehingga memiliki rata-rata 0 dan standar deviasi 1. Proses normalisasi ini memastikan bahwa tidak ada fitur yang mendominasi perhitungan jarak hanya karena skala nilainya yang lebih besar. Data yang telah dinormalisasi disimpan dalam matriks berukuran $n \times m$, dengan n adalah jumlah POI kandidat dan m adalah jumlah fitur.

Sebelum menjalankan algoritma *clustering*, perlu ditentukan terlebih dahulu jumlah *cluster* (k) yang paling sesuai dengan data. Dalam sistem ini, penentuan k dilakukan dengan menggabungkan dua metode evaluasi, yaitu metode Elbow (WCSS) dan Silhouette Score.

1. Metode Elbow: Untuk setiap nilai k (dibatasi maksimum 10), algoritma Intelligent K-Means dijalankan dan nilai Within-Cluster Sum of Squares (WCSS) dihitung. Nilai WCSS kemudian diplot terhadap k . Titik di mana penurunan WCSS mulai melambat (membentuk siku) dianggap sebagai kandidat k optimal.
2. Silhouette Score: Untuk setiap nilai k yang sama, dihitung rata-rata Silhouette Score. Metode ini mengukur seberapa baik setiap titik berada dalam *cluster*-

nya sendiri dibandingkan dengan *cluster* tetangganya. Nilai Silhouette berkisar antara -1 hingga 1, dengan nilai mendekati 1 menunjukkan *cluster* yang baik.

Sistem kemudian memilih nilai k dengan Silhouette Score tertinggi, namun tetap mempertimbangkan batasan bahwa k tidak boleh melebihi jumlah hari perjalanan yang dimasukkan pengguna. Jika nilai optimal lebih besar dari jumlah hari, maka jumlah hari itu sendiri yang digunakan sebagai k . Pendekatan ini memastikan bahwa hasil *clustering* tidak hanya optimal secara statistik tetapi juga praktis untuk perencanaan perjalanan.

Algoritma K-Means dipilih karena kemampuannya dalam menginisialisasi *centroid* secara cerdas, sehingga menghindari konvergensi pada optimum lokal yang sering terjadi pada K-Means standar. Proses inisialisasi dilakukan sebagai berikut:

1. Memilih centroid secara acak dari data POI.
2. Menghitung jarak terpendek ke *centroid* yang telah dipilih untuk setiap titik data ($D(x)$)
3. Memilih *Centroid* berikutnya dengan probabilitas sebanding dengan kuadrat jarak:
4. Langkah 2 dan 3 diulang hingga diperoleh sebanyak k *centroid* awal.

Pendekatan ini memastikan bahwa *centroid* awal tersebar dengan baik dan mencakup area yang beragam dalam ruang fitur. Setelah inisialisasi, algoritma K-Means++ melakukan iterasi hingga konvergen melalui langkah-langkah berikut:

1. Alokasi data ke *centroid*

Untuk setiap titik data x_i , dihitung jarak Euclidean ke setiap *centroid*. Titik tersebut kemudian dialokasikan ke *centroid* dengan jarak terpendek dengan rumus (2,n). Hal ini memastikan setiap data hanya menjadi anggota untuk satu *cluster*.

2. Pembaruan *centroid*

Setelah semua data dialokasikan, *centroid* diperbarui dengan menghitung rata-rata semua data dalam *cluster* dengan rumus (2,n). Dengan n adalah jumlah data dalam *cluster*.

3. Evaluasi konvergensi

Langkah 1 dan 2 diulang hingga tidak ada perubahan alokasi data antar iterasi, atau perubahan nilai *centroid* berada di bawah ambang batas yang ditentukan

Setelah konvergensi tercapai, setiap POI memiliki label *cluster* yang menunjukkan kelompoknya. Selain itu, sistem juga menghasilkan:


1. Pusat cluster (*centroid*) dalam skala asli (setelah *inverse transform* dari normalisasi), yang berguna untuk interpretasi karakteristik masing-masing *cluster*.
2. Ringkasan *cluster*, seperti jumlah anggota, rata-rata nilai fitur, serta kata kunci dominan yang diambil dari deskripsi POI dalam *cluster* tersebut.

Kualitas *cluster* dievaluasi menggunakan dua metrik:

1. Silhouette Score: Mengukur kohesi dan separasi *cluster* secara keseluruhan.

2. Davies-Bouldin Index (DBI) : Mengukur rasio antara dispersi internal *cluster* dengan jarak antar *centroid*. Semakin kecil DBI, semakin baik kualitas *cluster*.

Hasil clustering ini kemudian disimpan dalam basis data dan siap ditampilkan kepada pengguna pada antarmuka pemilihan *cluster*. Pengguna dapat melihat ringkasan setiap *cluster* dan memilih POI satu per satu dari *cluster* yang tersedia untuk menyusun rencana perjalanan harian.



Gambar 3. 12 Diagram Alur Intelligent K-Means

3.2.7 Skema Interaksi Pemilihan destinasi dalam *Cluster* oleh Pengguna

Setelah proses *clustering* dengan Intelligent K-Means++ selesai dilakukan, sistem menghasilkan sejumlah kelompok (*cluster*) destinasi wisata yang memiliki karakteristik serupa. Tahap selanjutnya adalah memberikan kendali penuh kepada pengguna untuk memilih destinasi yang paling sesuai dengan keinginan mereka.

Interaksi ini dirancang agar pengguna dapat melihat ringkasan setiap *cluster*, menjelajahi daftar POI di dalamnya, dan secara mandiri memilih POI yang ingin dikunjungi untuk setiap hari perjalanan. Pendekatan ini memastikan bahwa sistem tidak hanya memberikan rekomendasi otomatis, tetapi juga memberikan fleksibilitas dan personalisasi tingkat tinggi.

Setelah proses *clustering* menghasilkan label untuk setiap POI, backend menyusun ringkasan informatif untuk masing-masing *cluster*. Ringkasan ini dikirim ke frontend melalui API dan ditampilkan dalam bentuk kartu atau panel yang mudah dipahami. Informasi yang disajikan meliputi nomor *cluster*, jumlah POI dalam *cluster*, rata-rata skor relevansi, rata-rata jarak ke halte, rata-rata jumlah fasilitas (restoran dan minimarket). Informasi ini membantu pengguna untuk memahami karakteristik masing-masing *cluster* sebelum memutuskan untuk melihat lebih detail.

3.2.8 Skema Optimasi Rute dengan Greedy Nearest Neighbor

Setelah pengguna menyelesaikan pemilihan POI per hari, tahap berikutnya adalah menyusun urutan kunjungan yang optimal dalam satu hari. Tujuan optimasi rute adalah meminimalkan total jarak tempuh sehingga wisatawan dapat menghemat waktu dan biaya transportasi. Algoritma yang digunakan adalah Greedy Nearest Neighbor (GNN), yang dipilih karena kesederhanaan, kecepatan komputasi, dan kemampuannya menghasilkan solusi mendekati optimal untuk jumlah POI yang tidak terlalu besar (umumnya 5–7 POI per hari).

Algoritma GNN bekerja dengan prinsip *greedy*, yaitu selalu memilih POI terdekat dari posisi saat ini yang belum dikunjungi. Prosesnya adalah sebagai berikut:

1. Inisialisasi: Titik awal adalah koordinat hotel. Daftar POI yang belum dikunjungi berisi semua POI yang telah dipilih untuk hari tersebut.
2. Pemilihan: Dari posisi saat ini, hitung jarak ke setiap POI yang belum dikunjungi menggunakan rumus Haversine. POI dengan jarak terpendek dipilih sebagai tujuan berikutnya.
3. Kunjungi: POI terpilih ditambahkan ke dalam rute, dan posisi saat ini diperbarui ke koordinat POI tersebut.
4. Ulangi: Langkah 2–3 diulang hingga semua POI dalam hari tersebut terlewati.
5. Hasil: Rute akhir berupa urutan kunjungan POI beserta total jarak tempuh.

3.2.9 Skema Visualisasi dan Antarmuka Pengguna

Antarmuka pengguna merupakan komponen krusial yang menjembatani interaksi antara pengguna dengan sistem rekomendasi rencana perjalanan wisata. Visualisasi yang informatif dan antarmuka yang intuitif akan meningkatkan pengalaman pengguna dalam merencanakan perjalanan. Oleh karena itu, perancangan antarmuka dan visualisasi dilakukan dengan mempertimbangkan aspek kemudahan penggunaan, kejelasan informasi, dan daya tarik visual. Antarmuka pengguna dibangun menggunakan *React* sebagai *library frontend*, dengan dukungan pustaka *React Leaflet* untuk peta interaktif. Struktur antarmuka terdiri dari tiga halaman utama:

1. Halaman *Input*:


Pengguna memasukkan jumlah hari, lokasi hotel, dan preferensi teks.

The screenshot shows the GoTrip website interface. At the top, there's a navigation bar with 'Beranda', 'Destinasi', 'Panduan', and 'Tentang'. Below this, a green banner states 'Didukung Kecerdasan Buatan (RAG + K-Means)'. The main heading is 'Rencanakan Perjalanan Wisata Jakarta Anda', followed by a subtext: 'Ceritakan impian liburan Anda, dan biarkan AI kami membangun Itinerary optimal dengan destinasi terbaik di Jakarta.' The form is titled 'Isi Detail Perjalanan Anda' and includes instructions: 'Semua informasi akan dianalisis oleh model AI untuk menghasilkan rekomendasi terbaik.' It contains three main input sections: 1. 'Lokasi Hotel / Titik Keberangkatan' with a location pin icon and a text input field containing 'Pilih hotel dari daftar atau ketik manual'. Below this, it says '221 hotel tersedia — pilih dari dropdown atau ketik nama.' 2. 'Jumlah Hari Perjalanan' with a calendar icon and a text input field containing '1 Hari'. 3. 'Preferensi Wisata Dianalisis AI (RAG)' with a text area containing an example: 'Contoh: Saya ingin mengunjungi museum bersejarah yang tenang dan dekat dengan tempat kuliner malam yang autentik. Lebih suka tempat yang tidak terlalu ramai dan mudah dijangkau transportasi umum...'. Below the text area, it says 'Semakin detail deskripsi Anda, semakin akurat rekomendasinya.' and '0 karakter'. At the bottom of the form, there's a 'Filter Wilayah Jakarta (Optional)' section with checkboxes for 'Jakarta Pusat', 'Jakarta Barat', 'Jakarta Timur', 'Jakarta Selatan', 'Jakarta Utara', and 'Kepulauan Seribu'. A note below says 'Biarkan kosong untuk mencari di seluruh wilayah DKI Jakarta.' At the very bottom of the form is a blue button with a magnifying glass icon and the text 'Cari Rekomendasi Destinasi'.

Gambar 3. 13 Halaman Input


2. Halaman Pemilihan Destinasi dalam *Cluster*:

Setelah *backend* mengembalikan hasil *clustering*, halaman ini menampilkan ringkasan setiap cluster dalam bentuk kartu. Pengguna dapat mengeksplorasi daftar POI dalam *cluster* dan memilih POI satu per satu untuk setiap hari. POI yang telah dipilih tidak akan muncul lagi di daftar.



Gambar 3. 14 Halaman Pemilihan Destinasi dalam Cluster

- Halaman Hasil: Menampilkan peta interaktif dengan rute hasil optimasi. Setiap hari diberi warna garis berbeda, dan penanda (pin) POI dilengkapi nomor urut kunjungan. Di samping peta, ditampilkan daftar perjalanan per hari beserta total jarak. Pengguna juga dapat mengunduh rencana dalam format PDF atau menyimpannya.



Gambar 3. 15 Halaman Visualisasi dalam Peta

DAFTAR PUSTAKA

- [1] S. Rani, K. N. Kholidah, and S. N. Huda, "A development of travel itinerary planning application using traveling salesman problem and k-means clustering approach," in *ACM International Conference Proceeding Series*, Association for Computing Machinery, Feb. 2018, pp. 327–331. doi: 10.1145/3185089.3185142.
- [2] T. C. Mayvani, R. Afin, A. R. Idialis, and S. Sariyani, "Analysis of Growth and Tourism Clusters in Madura," *Jurnal Ekonomi dan Studi Pembangunan*, vol. 14, no. 1, p. 59, Mar. 2022, doi: 10.17977/um002v14i12022p059.
- [3] A. Yahi, A. Chassang, L. Raynaud, H. Duthil, and D. H. Chau, "Aurigo: An interactive tour planner for personalized itineraries," in *International Conference on Intelligent User Interfaces, Proceedings IUI*, Association for Computing Machinery, Mar. 2015, pp. 275–285. doi: 10.1145/2678025.2701366.
- [4] BPS-Statistics Indonesia DKI Jakarta Province, "BADAN PUSAT STATISTIK PROVINSI DKI JAKARTA BPS-STATISTICS DKI JAKARTA PROVINCE," Feb. 2026. Accessed: Feb. 23, 2026. [Online]. Available: <https://jakarta.bps.go.id/en/pressrelease/2026/02/02/1260/growth-of-tourism-in-dki-jakarta-province--december-2025.html>
- [5] R. Albayouk, Z. al Aghbari, and I. Afyouni, "Crowd-Aware Itinerary Optimization via Clustered Multi-Agent Reinforcement Learning," in *33rd ACM SIGSPATIAL*

- International Conference on Advances in Geographic Information Systems, ACM SIGSPATIAL 2025*, Association for Computing Machinery, Inc, Dec. 2025, pp. 346–356. doi: 10.1145/3748636.3762744.
- [6] M. Furqan and R. Mahsyaf Adha, “Determination of The Closest Path Using The Greedy Algorithm,” *International Journal of Information System & Technology Akreditasi*, vol. 7, no. 5, pp. 333–340, 2024.
- [7] J. Vuurstaek *et al.*, “GTFS bus stop mapping to the OSM network,” *Future Generation Computer Systems*, vol. 110, pp. 393–406, Sep. 2020, doi: 10.1016/j.future.2018.02.020.
- [8] P. Dauni, M. D. Firdaus, R. Asfariani, M. I. N. Saputra, A. A. Hidayat, and W. B. Zulfikar, “Implementation of Haversine formula for school location tracking,” in *Journal of Physics: Conference Series*, Institute of Physics Publishing, Dec. 2019. doi: 10.1088/1742-6596/1402/7/077028.
- [9] L. Yen Yee, S. M. Letchumy Belaidan, N. Azlina Abd Rahman, and K. Shajaratuddur Harun, “Implementing K-Means Clustering Algorithm in Collaborative Trip Advisory and Planning System,” vol. 7, no. 2, pp. 723–740, 2019, [Online]. Available: <http://pen.ius.edu.ba>
- [10] S. Glaret Shirley, K. Subrahmanyam, D. Susrija, and P. Akhila, “K-Means Algorithm and Clustering Technique for A Recommender System,” *International Journal of Application on Sciences, Technology and Engineering*, vol. 1, no. 1, pp. 302–312, Feb. 2023, doi: 10.24912/ijaste.v1.i1.302-312.

- [11] S. M. A. H. Bukhari and W. C. Song, "K-Means++ Clustering-Based Approach for SDN Controller Placement in LEO Satellite Networks," *IEEE Access*, vol. 13, pp. 79771–79783, 2025, doi: 10.1109/ACCESS.2025.3565954.
- [12] E. Maria, E. Budiman, Haviluddin, and M. Taruk, "Measure distance locating nearest public facilities using Haversine and Euclidean Methods," in *Journal of Physics: Conference Series*, Institute of Physics Publishing, Mar. 2020. doi: 10.1088/1742-6596/1450/1/012080.
- [13] R. Aliguliyev and S. F. Tahirzada, "PERFORMANCE COMPARISON OF K-MEANS, PARALLEL K-MEANS AND K-MEANS++."
- [14] L. Jirpongopas, B. Lutz, J. Ebner, R. Vahidov, and D. Neumann, "Persuasive or Neutral? A Field Experiment on Generative AI in Online Travel Planning," Sep. 2025, [Online]. Available: <http://arxiv.org/abs/2509.14259>
- [15] "PROVISION AND DEVELOPMENT OF TOURISM AMENITIES IN THE CONTEXT OF TOURIST COMFORT AND SUSTAINABILITY IN THE ECONOMIC, SOCIOCULTURAL AND ENVIRONMENTAL IDENTITY OF TOURISM VILLAGES Kristiani HALAWA 1 , Haniek LISTYORINI 2 1,2 S1 Pariwisata, Sekolah Tinggi Ilmu Ekonomi Pariwisata Indonesia, Indonesia Corresponding author: Haniek Listyorini."
- [16] G. Yunanda, D. Nurjanah, and S. Meliana, "Recommendation System from Microsoft News Data using TF-IDF and Cosine Similarity Methods," *Building of Informatics, Technology and Science (BITS)*, vol. 4, no. 1, Jun. 2022, doi: 10.47065/bits.v4i1.1670.

- [17] J. Swacha and M. Gracel, "Retrieval-Augmented Generation (RAG) Chatbots for Education: A Survey of Applications," Apr. 01, 2025, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/app15084234.
- [18] W. A. F. B, S. R. Sumardi, N. N. Sari, and J. E. Simarmata, "Rute Pendistribusian Barang dengan Algoritma Nearest Neighbor," *MALCOM: Indonesian Journal of Machine Learning and Computer Science*, vol. 4, no. 3, pp. 894–900, May 2024, doi: 10.57152/malcom.v4i3.1355.
- [19] D. Sebastian, B. Mulyawan, and N. J. Perdana, "SISTEM REKOMENDASI PRODUK UNTUK PELANGGAN PERUSAHAAN DISTRIBUSI MENGGUNAKAN METODE COLLABORATIVE FILTERING DAN K-MEANS CLUSTERING," 2024.
- [20] J. M. Tavares and M. Kozak, "TOURISTS' PREFERENCES FOR THE ALL-INCLUSIVE SYSTEM AND ITS IMPACTS ON THE LOCAL ECONOMY," 2015. [Online]. Available: www.ejth.com
- [21] G. Sierpiński, M. Staniek, and I. Celiński, "Travel Behavior Profiling Using a Trip Planner," in *Transportation Research Procedia*, Elsevier B.V., 2016, pp. 1743–1752. doi: 10.1016/j.trpro.2016.05.140.
- [22] UN Tourism, "World Tourism Barometer : January 2025." Accessed: Feb. 23, 2026. [Online]. Available: https://en.unwto-ap.org/news/worldtourismbarometer_jan2025/
- [23] geo2day, "Extracts data of Jakarta from the OpenstreetMaps." Accessed: Feb. 02, 2026. [Online]. Available: <https://geo2day.com/asia/indonesia/jakarta.html>

[24] Mobility Database, "GTFS Transjakarta." Accessed: Feb. 02, 2026. [Online].

Available: <https://mobilitydatabase.org/feeds/gtfs/mdb-1909>

[25] "The Official Jakarta Tourism Guidebook." Accessed: Feb. 02, 2026. [Online].

Available:

https://fliphtml5.com/wegpu/blue/THE_OFFICIAL_JAKARTA_TOURISM_GUIDEBOOK_-_ENGLISH/

LAMPIRAN

LAMPIRAN 1

DATASET

Dataset OpenStreetMap

Tabel L 1. 1 Data POI OSM

osm_id	name	category	subcategory	lat	lon	raw_tags	province	district	subdistrict
3.16E+08	Menara Thamrin	building	yes	-61.855.903	1.068.220.693	['building': 'yes', 'bul	Jakarta Raya	Jakarta Pusat	Menteng
3.18E+08	Monumen Selamat Datang	historic	monument	-61.949.789	1.068.230.733	['historic': 'monume	Jakarta Raya	Jakarta Pusat	Menteng
1.36E+09	Gold's Gym	leisure	sports_centre	-62.916.542	106.800.954	['leisure': 'sports_ce	Jakarta Raya	Jakarta Selatan	Cilandak
1.4E+09	Taman Rasuna Gym	leisure	sports_centre	-6.220.172	1.068.367.839	['leisure': 'sports_ce	Jakarta Raya	Jakarta Selatan	Setiabudi
1.68E+09	Graha Jetcoms	building	office	-61.864.861	1.067.616.177	['building': 'office', 'y	Jakarta Raya	Jakarta Barat	Kebonjeruk
1.69E+09	Pulau Kaliang Besar	leisure	beach_resort	-56.617.687	1.065.680.787	['leisure': 'beach_re	Jakarta Raya	Kepulauan Seribu	Kepulauan Seribu Utara
1.69E+09	Pulau Sepa Beach Resort	leisure	beach_resort	-55.766.968	1.065.804.517	['leisure': 'beach_re	Jakarta Raya	Kepulauan Seribu	Kepulauan Seribu Utara
1.7E+09	Taman Kelurahan	leisure	playground	-57.382.896	1.066.019.311	['leisure': 'playgroun	Jakarta Raya	Kepulauan Seribu	Kepulauan Seribu Utara
1.7E+09	Hemelboom	historic	memorial	-61.176.519	1.068.556.011	['historic': 'memoria	Jakarta Raya	Jakarta Utara	Pademangan
1.87E+09	Lapangan Futsal & Badminton RT6/7 Pondok Kelapa	leisure	playground	-62.433.866	1.069.337.965	['leisure': 'playgroun	Jakarta Raya	Jakarta Timur	Duren Sawit
2.08E+09	Taman Among Putra	leisure	park	-62.993.343	1.068.949.899	['leisure': 'park', 'na	Jakarta Raya	Jakarta Timur	Cipayung
2.08E+09	Taman Apotik Hidup	leisure	park	-6.299.437	1.068.971.441	['leisure': 'park', 'na	Jakarta Raya	Jakarta Timur	Cipayung
2.08E+09	Taman Bekisar	leisure	park	-62.993.713	1.069.014.275	['leisure': 'park', 'na	Jakarta Raya	Jakarta Timur	Cipayung
2.08E+09	Taman Kaktus	leisure	park	-62.993.548	1.068.965.073	['leisure': 'park', 'na	Jakarta Raya	Jakarta Timur	Cipayung
2.08E+09	Taman Melati	leisure	park	-62.993.836	1.068.991.039	['leisure': 'park', 'na	Jakarta Raya	Jakarta Timur	Cipayung
2.1E+09	GreenPark View Apartement	building	residential	-61.539.291	1.067.194.311	['building': 'resident	Jakarta Raya	Jakarta Barat	Cengkareng
2.34E+09	Monumen Pahlawan Kalibata	historic	monument	-62.578.404	1.068.470.025	['historic': 'monume	Jakarta Raya	Jakarta Selatan	Pancoran
2.43E+09	Tugu Proklamasi	historic	monument	-62.032.131	1.068.468.522	['historic': 'monume	Jakarta Raya	Jakarta Pusat	Menteng
2.49E+09	Rusunawa Waduk Pluit	building	apartments	-61.103.209	106.799.534	['building': 'apartme	Jakarta Raya	Jakarta Utara	Penjaringan
3.01E+09	Bluebird Taxi Parking & Repairs	building	garage	-62.540.099	1.067.772.954	['building': 'garage',	Jakarta Raya	Jakarta Selatan	Kebayoran Lama
3.68E+09	Tugu Reformasi 12 Mei 1998	historic	boundary_stone	-61.672.739	106.788.819	['historic': 'boundar	Jakarta Raya	Jakarta Barat	Grogolpetamburan
3.72E+09	Elemen Estetik	historic	monument	-62.093.529	1.068.013.769	['historic': 'monume	Jakarta Raya	Jakarta Pusat	Tanahabang
3.78E+09	Pos Wilayah RT 006/03	building	yes	-62.840.223	1.068.114.929	['building': 'yes', 'bul	Jakarta Raya	Jakarta Selatan	Pasar Minggu
3.8E+09	Taman Bermain RT 01	leisure	playground	-60.972.674	1.069.577.292	['leisure': 'playgroun	Jakarta Raya	Jakarta Utara	Cilincing
3.8E+09	Pemancingan	leisure	fishing	-6.097.586	1.069.597.745	['leisure': 'fishing', 'r	Jakarta Raya	Jakarta Utara	Cilincing

Dataset *file stops* (GTFS):

Tabel L 1. 2 data *file stop* (GTFS)

stop_id	stop_name	stop_lat	stop_lon
B00001P	18 Office Park	-6.299.146	1.068.321
B00002P	ABA	-6.194.149	10.683.939
B00003P	Acacia Residence	-6.263.358	10.675.675
B00004P	ACC Simatupang	-6.304.475	10.684.858
B00005P	ACE Hardware	-6.387.532	10.682.738
B00006P	ACE Hardware Kelapa Gading	-6.157.009	10.689.905
B00008P	Adam Malik 1	-6.236.396	10.674.776
B00011P	Agrowisata Cilangkap	-6.339.786	1.069.013
B00013P	Ahmad Yani Pisangan Baru	-6.211.477	10.687.374
B00014P	Airy Eco Binus	-6.195.282	10.678.881
B00015P	Akademi Farmasi Mahadhika	-6.312.819	1.068.693
B00016P	Akbid Yaspen Tugu Ibu	-6.360.213	1.068.835
B00017P	Akper Fatmawati Pondok Labu	-6.313.187	10.679.931
B00018P	AKR Tower	-6.190.732	10.676.743

Data Buku Panduan:

1 Ancol Art Market Ancol Dreamland. Jl. Lodan Timur No.7, Pademangan  Ancol Art Market is aspiration center for local artists from Jakarta and Indonesia, established since 1975. Tourists and art collectors can directly watch the artists finishing their masterpieces in the Art Market and purchases the desired artwork. The art market also holds a traditional art show performance every weekend. www.ancol.com	3 Dunia Fantasi Ancol Dreamland. Jl. Lodan Timur No.7, Pademangan  Dunia Fantasi (Dufan) is the most historic and famous amusement park in Jakarta or even in Indonesia. Built at 1983, Dufan has continuously become a favorite travel destination, boasting various rides that can be enjoyed by tourists of all ages, all with Indonesian and international themes. www.ancol.com
2 Allianz Ecopark & Faunaland Ancol Dreamland. Jl. Lodan Timur No.7, Pademangan  Both destinations are the newest attraction in Ancol Dreamland Complex. At Allianz Ecopark, tourists can enjoy the beauty of city part and partake in various fun ecofriendly activities. Meanwhile, the Faunaland offers tourists different experience of playing with various exotic animal from all over the world. www.ancol.com	4 Ancol Lagoon Beach Ancol Dreamland. Jl. Lodan Timur No.7, Pademangan  Lagoon Beach is one of the six beaches located in Ancol Dreamland Area. This beach is very popular among tourists from all walks of lives where they can have a beachside picnic while playing with sands and swim in the ocean. The beach also often held dazzling water ski show, and offers many Instagram spots. www.ancol.com

Gambar L 1. 1 Data Destinasi Yang Diekstrak

LAMPIRAN 2

PERHITUNGAN PENCARIAN SEMANTIK

1. Data dan alat yang digunakan

Sumber data: tabel dari poi_enrich (atribut: nama destinasi, kategori, sub kategori, deskripsi) yang berisi 15 POI hasil ekstraksi dari buku panduan wisata dan digabung dengan data OSM.

Alat yang digunakan:

1. Ollama – Platform untuk menjalankan model embedding lokal
2. Model Embedding: nomic-embed-text (dimensi 768)
3. Library Python: pandas, numpy, ollama

Data POI yang diambil:

Tabel L 2. 1 Atribut Data POI untuk *Embedding*

Destinasi (Nama POI)	category	subcategory	description
Jetski Cafe	amenity	cafe	"travel destination..."
Baywalk Mall	shop	mall	"Pluit Muara ..."
Art: 1 New Museum	tourism	museum	"1 New owcasing..."
Pancasila Sakti Monument	historic	monument	"Golf Club..."
Cibubur Bee Park	leisure	park	"Buperta Cibubur..."
Gedung Kesenian Jakarta	tourism	museum	"The Jakarta..."
Senayan City	shop	mall	"Club Traveling..."
Taman Ismail Marzuki	leisure	park	"56 Jami..."
Proclamation Text Making Museum	tourism	museum	"Tugu Kunstkring..."
National Monument (Monas)	tourism	museum	"(Monas) 65..."
Textile Museum	tourism	museum	"dies Colonial..."

Gelora Bung Karno Main Stadium	leisure	park	"Main Stadium..."
Bank Indonesia Museum	tourism	museum	"During colonial..."
Satria Mandala Museum	tourism	museum	"a Amurva Bhumi..."
Senayan National Golf Club	shop	mall	"73 Senayan..."

2. Pembuatan Representasi Teks POI

Setiap POI direpresentasikan dalam bentuk teks gabungan yang terdiri dari nama, kategori, subkategori, dan deskripsi singkat. Format representasi yang digunakan:

Nama: [nama POI] | Kategori: [kategori] | Subkategori: [subkategori] | Deskripsi: [deskripsi]

Tabel L 2. 2 Representasi Teks POI (Contoh 3 POI)

No	Nama POI	Representasi Teks
1	Jetski Cafe	Nama: Jetski Cafe Kategori: amenity Subkategori: cafe Deskripsi: "travel destination serving Asian and Western fusion dishes. The specialty of this destination is the beautiful ocean view from the restaurant. Visitors can enjoy the sensation of dining accompanied by the sound of crashing waves, and the romantic atmosphere while enjoying the sunset in Jetski Café"
2	Baywalk Mall	Nama: Baywalk Mall Kategori: shop Subkategori: mall Deskripsi: "Pluit Muara Baru Modern Fish Baywalk Mall is modern Market is a complete, clean, shopping destination in North and comfortable seafood Jakarta, offering different market in Jakarta. Visitors concept from other malls and are able to freely pick their shopping centers. Apart from preferred sea products international brands, the mall with affordable price, to also provides resting spot be cooked and prepared with ocean view called the at available seafood located waterfront, perfect to escape in the second floor of the from the hustle and bustle market, to be enjoyed of the city while waiting ..."

3	Art: 1 New Museum	Nama: Art: 1 New Museum Kategori: tourism Subkategori: museum Deskripsi: "1 New owcasing the masterpieces of Indonesian contemporary legendary artists. The modern and well-designed museum interior makes this ART: 1 New a must visit destination for tourists, especially art lovers. There is also a comfortable outdoor café in the museum as a resting spot for visitors. Bounce Street Asia The name of Kelapa Gading derived from the yellow coconut trees that is native to this"
---	-------------------	--

Kueri Pengguna: "Saya suka tempat bersejarah dan museum"

3. Vektor *Embedding*

Vektor embedding dibuat menggunakan model "nomic-embed-text" melalui Ollama yang dijalankan melalui Ollama dengan menghasilkan vektor berdimensi 768.

Rumus:

Embedding = Ollama.embeddings(model,prompt)

Tabel L 2. 3 Vektor *Embedding*

NO	name	category	subcategory	dim1	dim2	dim3	dim4	dim5
1	Textile Museum	tourism	museum	-0.858	1.304	-4.143	-0.96	0.963
2	Art: 1 New Museum	tourism	museum	-1.171	1.707	-3.8	-0.778	0.453
3	Bank Indonesia Museum	tourism	museum	-0.5	1.63	-4.644	-0.726	0.613
4	National Monument (Monas)	tourism	museum	-0.808	2.213	-4.122	-0.789	0.798
5	Satria Mandala Museum	tourism	museum	-0.967	1.607	-3.872	-0.426	1.129
6	Proclamation Text Making Museum	tourism	museum	-1.214	2.175	-4.345	-1.019	0.601

7	Gedung Kesenian Jakarta	tourism	museum	-0.9	1.513	-4.229	-0.792	0.443
8	Taman Ismail Marzuki	leisure	park	-0.245	1.567	-3.833	-0.942	-0.07
9	Cibubur Bee Park	leisure	park	-0.103	1.558	-3.987	0.122	0.336
10	Pancasila Sakti Monument	historic	monument	0.034	0.688	-4.294	-1.134	1.532
11	Baywalk Mall	shop	mall	-1.155	1.009	-3.494	-1.337	0.34
12	Gelora Bung Karno Main Stadium	leisure	park	-0.071	2.613	-3.568	0.402	0.519
13	Jetski Cafe	amenity	cafe	-1.206	1.601	-4.241	-0.961	0.631
14	Senayan National Golf Club	shop	mall	-0.285	0.773	-3.929	-0.375	-0.155
15	Senayan City	shop	mall	-0.542	0.946	-3.705	-0.384	-0.021

kueri	dim
Saya suka tempat bersejarah dan museum	[-0.209; 0.929; -4.004; -0.708; 0.265]

4. Cosine Similarity

Rumus: rumus (2.1) dengan $n = 768$ (dimensi *embedding*).

1. $\vec{A}$ = vektor embedding POI
2. $\vec{B}$ = vektor embedding kueri
3. n = dimensi vektor (768)

Nilai cosine similarity berkisar antara -1 hingga 1, di mana semakin mendekati 1 berarti semakin mirip atau relevan.

Tabel L 2. 4 Hasil Perhitungan Cosine Similarity untuk Semua POI

Peringkat	Nama POI	Cosine Similarity
1	Textile Museum	0.7070190467788513
2	Art: 1 New Museum	0.700153530903282
3	Bank Indonesia Museum	0.6907049662949691
4	National Monument (Monas)	0.6833586170880654
5	Satria Mandala Museum	0.6598489582624931
6	Proclamation Text Making Museum	0.6465217805699319
7	Gedung Kesenian Jakarta	0.6413945461121517
8	Taman Ismail Marzuki	0.5619634845707768
9	Cibubur Bee Park	0.541799363857639
10	Pancasila Sakti Monument	0.5122129070423318
11	Baywalk Mall	0.5116955537922068
12	Gelora Bung Karno Main Stadium	0.5065046859051254
13	Jetski Cafe	0.46972769851138485
14	Senayan National Golf Club	0.46594949297866656
15	Senayan City	0.45651675693824306

Dalam penelitian ini tidak ada batasan, sehingga lokasi yang tersedia akan diproses semuanya ke tahap selanjutnya pada perhitungan fitur *clustering*.

Interpretasi:

Hasil Pemeringkatan pada Tabel L 1.3 menunjukkan bahwa POI dengan kategori dan sub kategori “museum” memiliki skor cosine similarity tertinggi terhadap kueri pengguna. Hal ini dikarenakan model "nomic-embed-text" menangkap makna semantik dari teks dan mencari relevansi antara POI dan kueri pengguna. POI yang tidak relevan misalnya (*cafe* dan *mall*) yang terbukti ada di peringkat bawah.

LAMPIRAN 3

PERHITUNGAN FITUR DATA SPASIAL UNTUK CLUSTERING

1. Data dan alat yang digunakan

Sumber Data (Penggunaan data koordinat lintang dan bujur):

1. Data POI Kandidat: Data POI OSM.

Tabel L 3. 1 Data POI OSM (Atribut Spasial)

No	Nama POI	Kategori	Subkategori	Latitude	Longitude
1	Jetski Cafe	amenity	cafe	-61.225.528	1.068.908.881
2	Baywalk Mall	shop	mall	-61.091.686	1.067.786.319
3	Art: 1 New Museum	tourism	museum	-61.339.599	1.068.121.194
4	Pancasila Sakti Monument	historic	monument	-69.133.097	1.069.046.022
5	Cibubur Bee Park	leisure	park	-63.455.973	1.068.722.481
6	Gedung Kesenian Jakarta	tourism	museum	-61.666.345	1.068.352.307
7	Senayan City	shop	mall	-62.277.027	1.067.980.955
8	Taman Ismail Marzuki	leisure	park	-61.910.546	1.068.383.332
9	Proclamation Text Making Museum	tourism	museum	-0.6200342	106.830.733
10	National Monument (Monas)	tourism	museum	-61.761.775	1.068.229.859
11	Textile Museum	tourism	museum	-61.886.373	1.068.095.279
12	Gelora Bung Karno Main Stadium	leisure	park	-62.144.049	1.067.990.858
13	Bank Indonesia Museum	tourism	museum	-61.371.772	1.068.133.197
14	Satria Mandala Museum	tourism	museum	-62.305.507	1.068.196.244
15	Senayan National Golf Club	shop	mall	-62.186.486	1.067.922.718

2. Data OSM: File `osm_jakarta.csv` yang berisi titik-titik fasilitas (restoran, minimarket) di Jakarta dengan kategori “restaurant”, “convenient”, atau nama destinasi dengan nama merek minimarket.
3. Data GTFS: File `stops.txt` yang berisi data halte transportasi umum Transjakarta.

Tabel L 3. 2 Data Halte Transjakarta

Stop ID	Nama Halte	Latitude	Longitude
123	Halte Bundaran HI	-61.923	1.068.234
456	Halte Monas	-61.754	1.068.229
789	Halte Tosari	-62.012	1.068.211
321	Halte Stasiun Kota	-61.376	1.068.145
654	Halte Harmoni	-61.623	1.068.289

4. Data Hotel: Koordinat hotel yang ditentukan pengguna dari OSM dengan kategori “hotel”.

Tools yang Digunakan:

1. Python dengan library pandas, numpy, geopy
2. Rumus Haversine untuk perhitungan jarak geografis

2. Perhitungan Jarak Ke Hotel dengan Rumus Haversine

Rumus Haversine digunakan untuk menghitung jarak geografis antara dua titik di permukaan bumi. Rumus ini memperhitungkan kelengkungan bumi sehingga menghasilkan perhitungan jarak yang akurat.

Rumus Haversine (2.11) dengan mencari jarak antara POI dengan koordinat hotel dan halte.

Langkah-langkah perhitungan:

1. Konversi koordinat dari derajat ke radian.
2. Hitung selisih lintang dan bujur dalam radian.
3. Hitung nilai a sesuai rumus.
4. Hitung jarak $d = R \times c$ dengan $c = 2 \times \arcsin(\sqrt{a})$

Contoh Perhitungan untuk POI (Baywalk Mall):

Koordinat POI : $lat_p = -6.1091686$, $lon_p = 106.7786319$

Koordinat Hotel : $lat_h = -6.127066$, $lon_h = 106.790564$

Langkah 1: Konversi ke radian

$$lat_p = -6.1091686 \times \frac{\pi}{180} = -0.106626$$

$$lat_h = -6.127066 \times \frac{\pi}{180} = -0.106938$$

$$lon_p = 106.7786319 \times \frac{\pi}{180} = 1.863636$$

$$lon_h = 106.790564 \times \frac{\pi}{180} = 1.853844$$

Langkah 2: Hitung selisih

$$\Delta lat = lat_p - lat_h = (-0.106626) - (-0.106938) = 0.000312 \text{ rad}$$

$$\Delta lon = lon_p - lon_h = 1.863636 - 1.853844 = 0.009792 \text{ rad}$$

Langkah 3: Hitung nilai a

$$a = \sin^2\left(\frac{0.000312}{2}\right) + \cos(-0.106938) \cdot \cos(-0.106626) \cdot \sin^2\left(\frac{0.009792}{2}\right)$$

$$\sin^2\left(\frac{0.000312}{2}\right) = \sin^2(0.000156) = 0.0000000156$$

$$\sin^2 = 2.439 \times 10^{-8}$$

$$\cos(-0.106938) = 0.994294$$

$$\cos(-0.106626) = 0.9944322$$

$$\sin\left(\frac{-0.000208}{2}\right) = \sin(-0.000104) = -0.000104$$

$$\sin^2 = 1.084 \times 10^{-8}$$

$$a = 2.439 \times 10^{-8} + (0.994294 \times 0.9944322 \times 1.084 \times 10^{-8})$$

$$a = 2.439 \times 10^{-8} + (0.988648 \times 1.084 \times 10^{-8})$$

$$a = 2.439 \times 10^{-8} + 1.072 \times 10^{-8} = 3.511 \times 10^{-8}$$

Langkah 4: Hitung jarak

$$c = 2 \times \arcsin \sqrt{3.511 \times 10^{-8}} = 2 \times \arcsin(0.000187) = 2 \times 0.0001874$$

$$= 0.0003748 \text{ rad}$$

$$d = 6.371.000 \times 0.0003748 \text{ rad} = 2387,8 \text{ meter}$$

Hasil perhitungan untuk semua POI:

Tabel L 3. 3 Jarak POI ke Hotel

No	Nama POI	Jarak ke Hotel (m)
1	Jetski Cafe	11103
2	Baywalk Mall	2388
3	Art: 1 New Museum	2503
4	Pancasila Sakti Monument	88329
A5	Cibubur Bee Park	25923
6	Gedung Kesenian Jakarta	6614
7	Senayan City	11221
8	Taman Ismail Marzuki	8861
9	Proclamation Text Making Museum	6532
10	National Monument (Monas)	7160
11	Textile Museum	9757
12	Gelora Bung Karno Main Stadium	2756
13	Bank Indonesia Museum	11947
14	Satria Mandala Museum	10185
15	Senayan National Golf Club	3427

3. Perhitungan Jarak ke Halte Transportasi Terdekat

Data halte transportasi umum diperoleh dari *file stops* GTFS Transjakarta.

Perhitungan jarak ke halte terdekat menggunakan rumus Haversine yang sama, dengan mencari jarak minimum antara setiap POI dan semua halte. Jarak ke setiap halte dihitung dengan rumus Haversine, kemudian diambil nilai minimum.

Keterangan: i = poi, j = halte

Tabel L 3. 4 Perhitungan Jarak Monas ke Berbagai Halte

Stop ID	Nama Halte	Jarak (meter)
456	Halte Monas	87
123	Halte Bundaran HI	1890
789	Halte Tosari	2450
654	Halte Harmoni	1230
321	Halte Stasiun Kota	4560

Jarak terdekat Monas ke halte = 87 meter (Halte Monas)

Tabel L 3. 5 Jarak ke Halte Terdekat

No	Nama POI	Jarak ke Halte (m)
1	Jetski Cafe	234
2	Baywalk Mall	91
3	Art: 1 New Museum	5
4	Pancasila Sakti Monument	35855
5	Cibubur Bee Park	6
6	Gedung Kesenian Jakarta	13
7	Senayan City	7
8	Taman Ismail Marzuki	66
9	Proclamation Text Making Museum	10655648
10	National Monument (Monas)	8
11	Textile Museum	2
12	Gelora Bung Karno Main Stadium	7
13	Bank Indonesia Museum	7
14	Satria Mandala Museum	3
15	Senayan National Golf Club	1

4. Perhitungan Fasilitas Pendukung

Fasilitas pendukung dihitung dalam radius 500 meter dari setiap POI menggunakan data OSM yang telah diklasifikasikan. Klasifikasi data OSM yang dilakukan:

Restoran → *amenity=restaurant, cafe, fast_food, food_court* → semua tempat makan.

Minimarket → *shop=convenience / name="nama merek minimarket"* → toko serba ada / minimarket

Contoh perhitungan untuk POI Nomor 7 (Gedung Kesenian Jakarta)

Data fasilitas dalam radius 500 meter dari Gedung Kesenian Jakarta:

Tabel L 3. 6 Fasilitas dalam Radius 500m dari Gedung Kesenian Jakarta

Jenis Fasilitas	Nama	Jarak (meter)
Restoran	Restoran Sederhana	120
Restoran	Kafe Pasar Baru	230
Restoran	Warung Makan Bu Tini	310
Restoran	Restoran Padang Surya	420
Restoran	Kafe Ijen	480
Minimarket	Indomaret Pasar Baru	150
Minimarket	Alfamart Juanda	280
Minimarket	Circle K Pasar Baru	390

Jumlah restoran dalam radius 500m = 5

Jumlah minimarket dalam radius 500m = 3

Hasil Perhitungan Fasilitas untuk Semua POI

Tabel L 3. 7 Jumlah Fasilitas dalam Radius 500m

No	Nama POI	Jumlah Restoran (500m)	Jumlah Minimarket (500m)
1	Jetski Cafe	2	0
2	Baywalk Mall	3	0
3	Art: 1 New Museum	9	4
4	Pancasila Sakti Monument	0	0
5	Cibubur Bee Park	0	0
6	Gedung Kesenian Jakarta	5	2
7	Senayan City	16	1
8	Taman Ismail Marzuki	11	2
9	Proclamation Text Making Museum	0	0
10	National Monument (Monas)	3	1
11	Textile Museum	0	5
12	Gelora Bung Karno Main Stadium	4	0
13	Bank Indonesia Museum	14	6
14	Satria Mandala Museum	11	4
15	Senayan National Golf Club	1	0

5. Tabel Fitur Lengkap untuk Clustering

Setelah semua fitur dihitung, diperoleh tabel data lengkap yang akan digunakan sebagai input untuk proses clustering dengan algoritma Intelligent K-Means.

Tabel L 3. 8 Fitur Data Geospasial Untuk Clustering

No	Nama POI	Latitude	Longitude	Jarak Hotel (m)	Jarak Halte (m)	Resto 500m	Minimarket 500m
1	Jetski Cafe	-61.225.528	1.068.908.881	11103	234	2	0
2	Baywalk Mall	-61.091.686	1.067.786.319	2388	91	3	0
3	Art: 1 New Museum	-61.339.599	1.068.121.194	2503	5	9	4

4	Pancasila Sakti Monument	-69.133.097	1.069.046.022	88329	35855	0	0
5	Cibubur Bee Park	-63.455.973	1.068.722.481	25923	6	0	0
6	Gedung Kesenian Jakarta	-61.666.345	1.068.352.307	6614	13	5	3
7	Senayan City	-62.277.027	1.067.980.955	11221	7	16	1
8	Taman Ismail Marzuki	-61.910.546	1.068.383.332	8861	66	11	2
9	National Monument (Monas)	-61.761.775	1.068.229.859	6532	8	3	1
10	Textile Museum	-61.886.373	1.068.095.279	7160	2	0	5
11	Gelora Bung Karno Main Stadium	-62.144.049	1.067.990.858	9757	7	4	0
12	Bank Indonesia Museum	-61.371.772	1.068.133.197	2756	7	14	6
13	Satria Mandala Museum	-62.305.507	1.068.196.244	11947	3	11	6
14	Senayan National Golf Club	-62.186.486	1.067.922.718	10185	1	1	0
15	Ancol Art Market	-61.318.625	1.068.211.828	3427	66	1	0
16	Taman Mini Indonesia Indah	-63.019.124	1.068.882.144	22238	193	3	0
17	Cibubur Scout Camping Ground	-63.506.583	1.068.777.814	26666	2	0	0
18	Cijantung City Forest	-63.073.687	1.068.589.442	21426	468	0	0

19	Cijantung Skate Park	-63.117.435	1.068.624.989	22021	34	1	0
20	Tidung Island	-57.981.252	1.064.989.506	48764	34603	0	0
21	Untung Jawa Island	-59.775.464	1.067.073.046	19005	7040	0	0
22	Vihara Dharma Jaya Toa Se Bio	-61.327.889	1.067.106.986	8853	174	1	0

Interpretasi Fitur untuk *Clustering*

Hasil perhitungan fitur di atas akan digunakan sebagai input untuk proses *clustering* dengan algoritma Intelligent K-Means. Beberapa hal yang dapat diinterpretasikan:

1. Art: 1 New Museum memiliki jarak terpendek dari hotel (2,503 km) dan fasilitas pendukung seperti restoran dan minimarket yang cukup banyak tersedia.
2. Textile Museum dan Bank Indonesia Museum memiliki jarak sangat dekat ke hotel dan fasilitas melimpah, cocok untuk kunjungan cepat di pusat kota.
3. Monas memiliki aksesibilitas transportasi terbaik dengan jarak hanya 87 meter ke halte terdekat.
4. Bank Indonesia Museum dan Art: 1 New Museum memiliki jumlah restoran dan minimarket tertinggi, menunjukkan kawasan dengan fasilitas lengkap.
5. Proclamation Text Making Museum dan Pancasila Sakti Monument minim fasilitas, memerlukan persiapan lebih bagi wisatawan.

Fitur-fitur ini akan dinormalisasi pada tahap berikutnya sebelum dilakukan *clustering* untuk memastikan semua fitur memiliki skala yang seimbang.

LAMPIRAN 4

PERHITUNGAN INTELLIGENT K-MEANS

1. Pemilihan Variabel Input

Langkah pertama dalam penerapan Intelligent K-Means adalah menentukan variabel numerik yang relevan untuk menjadi dasar pembentukan *cluster*. Variabel yang dipilih dapat merepresentasikan karakteristik suatu destinasi dan dapat dihitung jaraknya secara matematis. Dalam penelitian ini digunakan tujuh variabel yaitu koordinat lintang, koordinat bujur, skor preferensi (*similarity score*), jarak destinasi ke hotel, jarak destinasi ke halte, jumlah restoran, dan jumlah minimarket. Berikut adalah tabel yang menampilkan data sampel dari 22 destinasi sebagai input data POI untuk proses *clustering*.

Tabel L 4. 1 Data Fitur-Fitur POI

No	Nama POI	Latitude	Longitude	Cosine Similarity
1	Jetski Cafe	-61225528	1068908881	0,469727699
2	Baywalk Mall	-61091686	1067786319	0,511695554
3	Art: 1 New Museum	-61339599	1068121194	0,700153531
4	Pancasila Sakti Monument	-69133097	1069046022	0,512212907
5	Cibubur Bee Park	-63455973	1068722481	0,541799364
6	Gedung Kesenian Jakarta	-61666345	1068352307	0,641394546
7	Senayan City	-62277027	1067980955	0,456516757
8	Taman Ismail Marzuki	-61910546	1068383332	0,561963485
9	National Monument (Monas)	-61761775	1068229859	0,683358617
10	Textile Museum	-61886373	1068095279	0,707019047
11	Gelora Bung Karno Main Stadium	-62144049	1067990858	0,506504686
12	Bank Indonesia Museum	-61371772	1068133197	0,690704966
13	Satria Mandala Museum	-62305507	1068196244	0,659848958
14	Senayan National Golf Club	-62186486	1067922718	0,465949493
15	Ancol Art Market	-61318625	1068211828	0,543947082
16	Taman Mini Indonesia Indah	-63019124	1068882144	0,573816334
17	Cibubur Scout Camping Ground	-63506583	1068777814	0,554855214
18	Cijantung City Forest	-63073687	1068589442	0,557829138
19	Cijantung Skate Park	-63117435	1068624989	0,481663965
20	Tidung Island	-57981252	1064989506	0,510517504
21	Untung Jawa Island	-59775464	1067073046	0,520365393
22	Vihara Dharma Jaya Toa Se Bio	-61327889	1067106986	0,507956524

Tabel L 4.1 (Lanjutan)

Jarak Hotel (m)	Jarak Halte (m)	Resto 500m	Minimarket 500m
11103	234	2	0
2388	91	3	0
2503	5	9	4
88329	35855	0	0
25923	6	0	0
6614	13	5	3
11221	7	16	1
8861	66	11	2
6532	8	3	1
7160	2	0	5
9757	7	4	0
2756	7	14	6
11947	3	11	6
10185	1	1	0
3427	66	1	0
22238	193	3	0
26666	2	0	0
21426	468	0	0
22021	34	1	0
48764	34603	0	0
19005	7040	0	0
8853	174	1	0

2. Normalisasi Data

Tujuh data pada Tabel L 2.1 memiliki skala berbeda, maka perlu dilakukan proses normalisasi data dengan metode z-score standardization (2.2). Normalisasi ini bertujuan untuk mengurangi setiap nilai dengan rata-rata variabel, lalu membaginya dengan standar deviasi. Dengan demikian, semua variabel berada pada skala yang sebanding dan tidak ada variabel yang mendominasi. Berikut tabel hasil normalisasi dengan menampilkan nilai transformasi z-score untuk 22 data.

Tabel L 4. 2 Langkah perhitungan normalisasi data z-score

No	name	similarity	x-mean	std (global)	Z-score
1	Jetski Cafe	0,469727699	-0,0921	0,0813	-1,132
2	Baywalk Mall	0,511695554	-0,0501	0,0813	-0,6161
3	Art: 1 New Museum	0,700153531	0,1383	0,0813	1,7008
4	Pancasila Sakti Monument	0,512212907	-0,0496	0,0813	-0,6097
5	Cibubur Bee Park	0,541799364	-0,02	0,0813	-0,246
6	Gedung Kesenian Jakarta	0,641394546	0,0796	0,0813	0,9784
7	Senayan City	0,456516757	-0,1053	0,0813	-1,2945
8	Taman Ismail Marzuki	0,561963485	0,0002	0,0813	0,0019
9	National Monument (Monas)	0,683358617	0,1215	0,0813	1,4943
10	Textile Museum	0,707019047	0,1452	0,0813	1,7852
11	Gelora Bung Karno Main Stadium	0,506504686	-0,0553	0,0813	-0,6799
12	Bank Indonesia Museum	0,690704966	0,1289	0,0813	1,5846
13	Satria Mandala Museum	0,659848958	0,098	0,0813	1,2053
14	Senayan National Golf Club	0,465949493	-0,0959	0,0813	-1,1785
15	Ancol Art Market	0,543947082	-0,0179	0,0813	-0,2196
16	Taman Mini Indonesia Indah	0,573816334	0,012	0,0813	0,1476
17	Cibubur Scout Camping Ground	0,554855214	-0,007	0,0813	-0,0855
18	Cijantung City Forest	0,557829138	-0,004	0,0813	-0,0489
19	Cijantung Skate Park	0,481663965	-0,0801	0,0813	-0,9853
20	Tidung Island	0,510517504	-0,0513	0,0813	-0,6306
21	Untung Jawa Island	0,520365393	-0,0414	0,0813	-0,5095
22	Vihara Dharma Jaya Toa Se Bio	0,507956524	-0,0539	0,0813	-0,6621
Rata-rata Cosine Similarity		0,5618			
Standard Deviasi Cosine Similarity		0,0813			

Tabel L 4. 3 Hasil Perhitungan Normalisasi Data

No	Sim_z	JHotel_z	JHalte_z	Resto_z	Minim_z	Lat_z	Lon_z
1	-1,1587	-0,3221	-0,3314	-0,3824	-0,6211	0,466	0,9653
2	-0,6306	-0,7851	-0,3456	-0,1772	-0,6211	0,5349	-0,3687
3	1,7408	-0,779	-0,3541	1,0539	1,331	0,4073	0,0292
4	-0,6241	3,7803	3,1909	-0,7927	-0,6211	-3,6047	1,1282
5	-0,2518	0,4651	-0,354	-0,7927	-0,6211	-0,6822	0,7438
6	1,0014	-0,5606	-0,3533	0,2332	0,843	0,239	0,3039
7	-1,3249	-0,3159	-0,3539	2,4901	-0,1331	-0,0753	-0,1374

8	0,0019	-0,4413	-0,348	1,4642	0,3549	0,1133	0,3407
9	1,5295	-0,565	-0,3538	-0,1772	-0,1331	0,1899	0,1583
10	1,8272	-0,5316	-0,3544	-0,7927	1,8191	0,1258	-0,0016
11	-0,6959	-0,3937	-0,3539	0,028	-0,6211	-0,0069	-0,1257
12	1,6219	-0,7656	-0,3539	2,0798	2,3071	0,3907	0,0435
13	1,2337	-0,2773	-0,3543	1,4642	2,3071	-0,09	0,1184
14	-1,2062	-0,3709	-0,3545	-0,5876	-0,6211	-0,0287	-0,2066
15	-0,2248	-0,7299	-0,348	-0,5876	-0,6211	0,418	0,1369
16	0,1511	0,2694	-0,3355	-0,1772	-0,6211	-0,4573	0,9335
17	-0,0875	0,5046	-0,3544	-0,7927	-0,6211	-0,7083	0,8095
18	-0,0501	0,2262	-0,3083	-0,7927	-0,6211	-0,4854	0,5857
19	-1,0085	0,2578	-0,3512	-0,5876	-0,6211	-0,5079	0,6279
20	-0,6454	1,6785	3,0671	-0,7927	-0,6211	2,1361	-3,6923
21	-0,5215	0,0976	0,3416	-0,7927	-0,6211	1,2124	-1,2164
22	-0,6776	-0,4417	-0,3374	-0,5876	-0,6211	0,4133	-1,176

3. Penentuan Jumlah *Cluster*

Tahap ini menentukan jumlah *cluster* optimal menggunakan Elbow Method dan Silhouette Coefficient. Elbow Method mengevaluasi nilai WCSS (Within-Cluster Sum of Squares) untuk beberapa kemungkinan jumlah *cluster* yang terbentuk dengan rumus (2.3), sedangkan Silhouette Coefficient menilai kualitas dari *cluster* yang terbentuk dengan mempertimbangkan kohesi dan separasi dengan rumus (2.4). Berdasarkan hasil perhitungan, jumlah *cluster* optimal berada pada $k = 4$ (untuk kebutuhan perhitungan manual maka nilai k yang dipilih 3). Tabel berikut menampilkan nilai WCSS dan Silhouette untuk setiap k yang diuji.

Tabel L 4. 4 Hasil perhitungan WCSS per data (data ke-1)

Fitur	x (data)	c (centroid)	diff (x - c)	(diff) ²
Cosine Similarity	-1,1587	-0,5952	-0,5635	0,3175
Jarak Hotel (m)	-0,3221	0,01	-0,3322	0,1103
Jarak Halte (m)	-0,3314	-0,0514	-0,28	0,0784
Resto 500m	-0,3824	-0,3238	-0,0586	0,0034

Minimarket 500m	-0,6211	-0,5863	-0,0349	0,0012
Latitude	0,466	0,1592	0,3068	0,0941
Longitude	0,9653	-0,1515	1,1167	1,2471
Jumlah				1,8522

Tabel L 4. 5 Hasil SUM keseluruhan data pada WCSS k=3

Data kei-	Nama POI	Cluster	Kontribusi WCSS
1	Jetski Cafe	2	1,8522
2	Baywalk Mall	2	0,931
3	Art: 1 New Museum	1	0,4086
4	Pancasila Sakti Monument	3	0
5	Cibubur Bee Park	2	2,1472
6	Gedung Kesenian Jakarta	1	0,5587
7	Senayan City	2	8,9086
8	Taman Ismail Marzuki	1	3,0092
9	National Monument (Monas)	1	2,887
10	Textile Museum	1	3,0508
11	Gelora Bung Karno Main Stadium	2	0,4178
12	Bank Indonesia Museum	1	3,0403
13	Satria Mandala Museum	1	1,7533
14	Senayan National Golf Club	2	0,7195
15	Ancol Art Market	2	0,9937
16	Taman Mini Indonesia Indah	2	2,2848
17	Cibubur Scout Camping Ground	2	2,4913
18	Cijantung City Forest	2	1,5899
19	Cijantung Skate Park	2	1,4454
20	Tidung Island	2	29,1779
21	Untung Jawa Island	2	2,632
22	Vihara Dharma Jaya Toa Se Bio	2	1,4777
Total WCSS			71,7769

Tabel L 4. 6 Perhitungan Silhouette (k=3)

No	Nama POI	Cluster	a(i)	b(i)	s(i)
1	Jetski Cafe	2	2,1488	3,6091	0,4046
2	Baywalk Mall	2	1,9711	3,1547	0,3752
3	Art: 1 New Museum	1	1,6787	3,8923	0,5687
4	Pancasila Sakti Monument	3	0	6,6613	1
5	Cibubur Bee Park	2	2,056	3,4517	0,4044
6	Gedung Kesenian Jakarta	1	1,7083	2,9144	0,4138
7	Senayan City	2	3,6158	3,6441	0,0078
8	Taman Ismail Marzuki	1	2,3914	2,7978	0,1453
9	National Monument (Monas)	1	2,3085	2,8508	0,1902
10	Textile Museum	1	2,3865	3,9436	0,3948
11	Gelora Bung Karno Main Stadium	2	1,8051	3,0876	0,4154
12	Bank Indonesia Museum	1	2,3052	4,8235	0,5221
13	Satria Mandala Museum	1	2,0144	4,3105	0,5327
14	Senayan National Golf Club	2	1,8967	3,6332	0,478
15	Ancol Art Market	2	1,9399	3,0072	0,3549
16	Taman Mini Indonesia Indah	2	2,1539	2,9775	0,2766
17	Cibubur Scout Camping Ground	2	2,1361	3,4134	0,3742
18	Cijantung City Forest	2	1,9516	3,2209	0,3941
19	Cijantung Skate Park	2	1,9789	3,666	0,4602
20	Tidung Island	2	5,9452	6,84	0,1308
21	Untung Jawa Island	2	2,5672	3,8198	0,3279
22	Vihara Dharma Jaya Toa Se Bio	2	2,2018	3,5405	0,3781
Rata-rata Silhouette Score					0,3365

Tabel L 4. 7 Nilai WCSS dan Silhouette untuk Berbagai k

k	WCSS	Silhouette Score
2	109,8137336	0,307843059
3	71,77694506	0,343169492
4	40,35457197	0,376305211
5	29,22123892	0,367584341
6	20,72381689	0,332897646
7	14,00557083	0,341870666

4. Inisialisasi Centroid

Centroid awal ditentukan dengan metode Intelligent K-means, yaitu pendekatan Intelligent K-Means yang memilih centroid secara lebih sistematis agar tersebar merata, di mana centroid berikutnya dipilih berdasarkan probabilitas (2.5) sebanding kuadrat jarak terdekat $D(x)^2$. Hal ini mengurangi risiko hasil clustering terjebak pada solusi lokal optimum. Tabel berikut memperlihatkan nilai centroid awal pada ketujuh variabel untuk masing-masing cluster.

Tabel L 4. 8 Perhitungan manual Centroid dengan data 7 sebagai centroid awal

No	Nama POI	$D(x)^2$ K2	P(x) K2	$D(x)^2$ K3	P(x) K3
1	Jetski Cafe	10,0265	0,0299	10,0265	0,0358
2	Baywalk Mall	8,4809	0,0253	8,4809	0,0303
3	Art: 1 New Museum	14,0804	0,042	14,0804	0,0503
4	Pancasila Sakti Monument	54,9087	0,1639	0	0
5	Cibubur Bee Park	13,9217	0,0416	13,9217	0,0497
6	Gedung Kesenian Jakarta	1,1812	0,0353	1,1812	0,0422
7	Senayan City	0	0	0	0
8	Taman Ismail Marzuki	3,3312	0,0099	3,3312	0,0119
9	National Monument (Monas)	15,4821	0.0462	15,4821	0,0553
10	Textile Museum	24,6295	0.0735	24,6295	0,088
11	Gelora Bung Karno Main Stadium	6,7068	0.02	6,7068	0,024
12	Bank Indonesia Museum	15,2591	0.0456	15,2591	0,0545
13	Satria Mandala Museum	13,6207	0.0407	13,6207	0,0486
14	Senayan National Golf Club	9,7343	0.0291	9,7343	0,0348
15	Ancol Art Market	11,4107	0.0341	11,4107	0,0408
16	Taman Mini Indonesia Indah	1,1167	0.0333	1,1167	0,0399
17	Cibubur Scout Camping Ground	1,4517	0.0433	1,4517	0,0518
18	Cijantung City Forest	13,6275	0.0407	13,6275	0,0487
19	Cijantung Skate Park	10,9124	0.0326	10,9124	0,039
20	Tidung Island	44,6848	0.1334	44,6848	0,1596
21	Untung Jawa Island	15,1377	0.0452	15,1377	0,0541
22	Vihara Dharma Jaya Toa Se Bio	11,4627	0.0342	11,4627	0,0409

Tabel L 4. 9 Inisialisasi centroid untuk masing-masing fitur

Cluster	Latitude	Longitude	Cosine Similarity
0	- 61748845,29	1068215916	0,6635
1	- 61821486,29	1067969141	0,5145
2	-69133097	1069046022	0,5122

Tabel L 4.9 (lanjutan)

Jarak Hotel (m)	Jarak Halte (m)	Resto 500m	Minimarket 500m
6624,7143	14,8571	7,5714	3,8571
17355,5	3066,1429	2,2857	0,0714
88329	35855	0	0

Tabel L 4. 10 Inisialisasi centroid dengan Intelligent K-Means iterasi ke-1

No	Latitude	Longitude	Cosine Similarity
7	-62277027.0	1067980955.0	0.4565
4	-69133097.0	1069046022.0	0.5122
20	-57981252.0	1064989506.0	0.5105

Tabel L 4.11 (lanjutan)

Jarak Hotel (m)	Jarak Halte (m)	Resto 500m	Minimarket 500m
11221.0	7.0	16.0	1.0
88329.0	35855.0	0.0	0.0
48764.0	34603.0	0.0	0.0

5. Perhitungan jarak data ke *centroid*

Setelah centroid awal ditetapkan, dilakukan perhitungan jarak antara setiap data dengan masing-masing centroid menggunakan Euclidean Distance (2.6). Perhitungan ini dilakukan dalam ruang multidimensi sehingga

memperhitungkan seluruh variabel. Tabel berikut menunjukkan jarak tiap data ke semua centroid pada iterasi pertama.

Tabel L 4. 11 Perhitungan jarak Ecludian antar data

Fitur	X1 (data ke-1)	C2 (centroid-2)	(X1 - C2)	(X1 - C2) ²
Cosine Similarity	-1,1587	-0,5952	-0,5635	0,3175
Jarak Hotel (m)	-0,3221	0,01	-0,3322	0,1103
Jarak Halte (m)	-0,3314	-0,0514	-0,28	0,0784
Resto 500m	-0,3824	-0,3238	-0,0586	0,0034
Minimarket 500m	-0,6211	-0,5863	-0,0349	0,0012
Latitude	0,466	0,1592	0,3068	0,0941
Longitude	0,9653	-0,1515	1,1167	1,2471
Jumlah kuadrat	1,8522			
Jarak Euclidean	1,3609			

Tabel L 4. 12 Hasil jarak Euclidean seluruh data dengan *cluster*

Nama POI	C0	C1	C2
Jetski Cafe	3,4063	1,3609	6,8035
Baywalk Mall	2,9151	0,9649	7,2873
Art: 1 New Museum	0,6392	3,4408	7,9669
Pancasila Sakti Monument	7,5101	6,3839	0
Cibubur Bee Park	3,2384	1,4653	5,6907
Gedung Kesenian Jakarta	0,7475	2,3522	7,2593
Senayan City	3,4539	2,9847	7,41
Taman Ismail Marzuki	1,7347	2,2305	7,1574
National Monument (Monas)	1,6991	2,2935	7,2139
Textile Museum	1,7467	3,5046	7,6366
Gelora Bung Karno Main Stadium	2,8502	0,6463	6,7218
Bank Indonesia Museum	1,7437	4,4552	8,4994
Satria Mandala Museum	1,3241	3,9016	7,7152
Senayan National Golf Club	3,4276	0,8482	6,6897
Ancol Art Market	2,7753	0,9968	7,0875
Taman Mini Indonesia Indah	2,7275	1,5116	5,9737
Cibubur Scout Camping Ground	3,1975	1,5784	5,6637
Cijantung City Forest	3,0012	1,2609	5,9354
Cijantung Skate Park	3,4638	1,2023	5,9147

Tidung Island	6,6957	5,4017	7,7863
Untung Jawa Island	3,6045	1,6223	7,0988
Vihara Dharma Jaya Toa Se Bio	3,3151	1,2156	7,1953

6. Alokasi data ke *cluster*

Berdasarkan hasil penghitungan jarak, setiap data dialokasikan ke *cluster* dengan centroid terdekat (r_{ij}). Hal ini memastikan bahwa tiap data hanya menjadi anggota dari satu *cluster*. Tabel berikut menunjukkan hasil alokasi 22 data ke *cluster* masing-masing.

Tabel L 4. 13 Hasil Alokasi Data

Nama POI	C0	C1	C2
Jetski Cafe	3,4063	1,3609	6,8035
Baywalk Mall	2,9151	0,9649	7,2873
Art: 1 New Museum	0,6392	3,4408	7,9669
Pancasila Sakti Monument	7,5101	6,3839	0
Cibubur Bee Park	3,2384	1,4653	5,6907
Gedung Kesenian Jakarta	0,7475	2,3522	7,2593
Senayan City	3,4539	2,9847	7,41
Taman Ismail Marzuki	1,7347	2,2305	7,1574
National Monument (Monas)	1,6991	2,2935	7,2139
Textile Museum	1,7467	3,5046	7,6366
Gelora Bung Karno Main Stadium	2,8502	0,6463	6,7218
Bank Indonesia Museum	1,7437	4,4552	8,4994
Satria Mandala Museum	1,3241	3,9016	7,7152
Senayan National Golf Club	3,4276	0,8482	6,6897
Ancol Art Market	2,7753	0,9968	7,0875
Taman Mini Indonesia Indah	2,7275	1,5116	5,9737
Cibubur Scout Camping Ground	3,1975	1,5784	5,6637
Cijantung City Forest	3,0012	1,2609	5,9354
Cijantung Skate Park	3,4638	1,2023	5,9147
Tidung Island	6,6957	5,4017	7,7863
Untung Jawa Island	3,6045	1,6223	7,0988

Vihara Dharma Jaya Toa Se Bio	3,3151	1,2156	7,1953
-------------------------------	--------	--------	--------

7. Fungsi Objektif

Fungsi objektif K-Means adalah meminimalkan nilai Within-Cluster Sum of Squares (WCSS), yaitu total kuadrat jarak antara data dan centroid clusternya (2,8). Nilai WCSS dihitung dengan menjumlahkan kontribusi dari tiap data. Tabel berikut menampilkan nilai total WCSS pada iterasi pertama, dengan contoh perhitungan manual ditunjukkan untuk satu data agar transparansi proses lebih jelas.

Tabel L 4. 14 Perhitungan fungsi objektif

Data ke-	Nama POI	Cluster	Kontribusi WCSS
1	Jetski Cafe	2	1.8522
2	Baywalk Mall	2	0.931
3	Art: 1 New Museum	1	0.4086
4	Pancasila Sakti Monument	3	0
5	Cibubur Bee Park	2	2.1472
6	Gedung Kesenian Jakarta	1	0.5587
7	Senayan City	2	8.9086
8	Taman Ismail Marzuki	1	3.0092
9	National Monument (Monas)	1	2.887
10	Textile Museum	1	3.0508
11	Gelora Bung Karno Main Stadium	2	0.4178
12	Bank Indonesia Museum	1	3.0403
13	Satria Mandala Museum	1	1.7533
14	Senayan National Golf Club	2	0.7195
15	Ancol Art Market	2	0.9937
16	Taman Mini Indonesia Indah	2	2.2848
17	Cibubur Scout Camping Ground	2	2.4913
18	Cijantung City Forest	2	1.5899
19	Cijantung Skate Park	2	1.4454
20	Tidung Island	2	29.1779

21	Untung Jawa Island	2	2.632
22	Vihara Dharma Jaya Toa Se Bio	2	1.4777

8. Pembaruan *Centroid*

Setelah data dialokasikan, centroid diperbarui dengan menghitung rata-rata nilai semua data dalam masing-masing *cluster* (2,9). Proses ini menghasilkan centroid baru yang lebih representatif terhadap distribusi anggotanya. Tabel berikut menampilkan hasil update centroid pada iterasi pertama.

Tabel L 4. 15 Hasil pembaruan akhir iterasi Intelligent K-Means titik centroid

Centroid id	Cosine Similarity	Jarak Hotel (m)	Jarak Halte (m)	Rest o 500 m	Minimarket 500m	Latitude	Longitude
C1	0.5669	12029.3	421.35	4.25	1.4	-61988073.65	1068204493.65
C2	0.5122	88329.0	35855.0	0.0	0.0	-69133097.0	1069046022.0
C3	0.5105	48764.0	34603.0	0.0	0.0	-57981252.0	1064989506.0

9. Evaluasi Kualitas *Clustering*

Lampiran ini menyajikan hasil evaluasi kualitas clustering menggunakan metode K-Means dengan jumlah *cluster* ($k = 3$). Evaluasi dilakukan dengan dua ukuran utama, yaitu Silhouette Coefficient (2.4) dan Davies-Bouldin Index (DBI) (2.10). Silhouette dilakukan secara otomatis menggunakan fungsi `silhouette_score` dari `scikit-learn`, sedangkan DBI dihitung secara manual melalui

tahapan perhitungan jarak data terhadap centroid, rata-rata jarak dalam *cluster* (s_i), jarak antar centroid, rasio r_{ij} , hingga nilai rata-rata maksimum per *cluster*.

Tabel L 4. 16 Rata-rata jarak intra-cluster

Cluster	Rata-rata jarak intra-cluster (S_i)
0	1,376420641
1	1,64714611
2	0

Tabel L 4. 17 Jarak hasil antar tiap *centroid masing-masing*

Pasangan	Jarak
C0–C1	2,933869
C0–C2	7,510105
C1–C2	6,383863

Tabel L 4. 18 Perhitungan untuk menghasilkan rasio R

No	Perhitungan Rij	S_i	S_j	M_{ij}	Hasil Rij
1	$R_{1,2} = (S_1 + S_2) / M_{1,2}$	1,3764	1,6471	2,9339	1,0306
2	$R_{1,3} = (S_1 + S_3) / M_{1,3}$	1,3764	0	7,5101	0,1833
3	$R_{2,1} = (S_2 + S_1) / M_{2,1}$	1,6471	1,3764	2,9339	1,0306

Tabel L 4. 19 Hasil akhir nilai maksimum R tiap *cluster*

No	Cluster	Maksimum Rij
1	C1	1.0306
2	C2	1.0306
3	C3	0.2580

$$DBI = \frac{1,0306 + 1,306 + 0,2580}{3} = 0,7730$$

Hasil Evaluasi akhir:

Hasil Silhouette Coefficient Manual Tabel L 3.6: 0.4031

Davies-Bouldin Index: 0,7730

LAMPIRAN 5

PERHITUNGAN OPTIMASI RUTE

Pada Lampiran 4 ini disajikan perhitungan optimasi rute kunjungan menggunakan algoritma *Greedy Nearest Neighbor* (GNN) berdasarkan data 5 titik POI yang telah dipilih. Proses perhitungan meliputi pembersihan koordinat, pembentukan matriks jarak antar POI dan dari hotel, penerapan algoritma GNN, serta penyajian rute akhir beserta total jarak tempuh.

Data yang digunakan berasal dari hasil *clustering* (Lampiran 3) yang terdiri atas 5 destinasi wisata di Jakarta (data POI *cluster* 1). Koordinat diperoleh dari nilai bilangan bulat yang kemudian dibagi dengan faktor 1×10^7 untuk mendapatkan format derajat desimal yang benar. Rincian data POI disajikan pada Tabel L 4.1.

Tabel L 5. 1 Data POI koordinat

Nama POI	Latitude	Longitude
Art: 1 New Museum	-6,1339599	106,8121194
Gedung Kesenian Jakarta	-6,1666345	106,8352307
Taman Ismail Marzuki	-6,1910546	106,8383332
National Monument (Monas)	-6,1761775	106,8229859
Textile Museum	-6,1886373	106,8095279

Titik awal (hotel) ditetapkan pada koordinat (-6,1270664, 106,7905636) yang diperoleh dari pembagian bilangan bulat dengan faktor 1×10^7 .

Jarak antar titik dihitung menggunakan rumus Haversine untuk memperhitungkan kelengkungan bumi. Rumus yang digunakan: dengan $R = 6371$ km (dalam meter: 6.371.000 m). Matriks jarak antar POI (dalam meter)

disajikan pada Tabel L 4.2. Nilai ini menjadi dasar pemilihan tetangga terdekat dalam algoritma.

Tabel L 5. 2 Matriks jarak antar POI (dalam meter)

POI	Art: 1 New Museum	Gedung Kesenian Jakarta	Taman Ismail Marzuki	National Monument (Monas)	Textile Museum
Art: 1 New Museum	0	4441,72	6978,8	4845,66	6086,6
Gedung Kesenian Jakarta	4441,72	0	2736,97	1720,01	3749,61
Taman Ismail Marzuki	6978,8	2736,97	0	2369,61	3195,65
National Monument (Monas)	4845,66	1720,01	2369,61	0	2032,96
Textile Museum	6086,6	3749,61	3195,65	2032,96	0


Algoritma *Greedy Nearest Neighbor* bekerja dengan prinsip memilih destinasi terdekat dari posisi saat ini secara berulang hingga semua titik dikunjungi. Langkah-langkahnya adalah sebagai berikut:

1. Mulai dari hotel sebagai titik awal.
2. Cari POI yang belum dikunjungi dengan jarak terpendek dari posisi saat ini.
3. Kunjungi POI tersebut, jadikan sebagai posisi baru, dan catat jarak tempuh.
4. Ulangi langkah 2–3 hingga semua POI dikunjungi.
5. Hitung total jarak dengan menjumlahkan seluruh segmen perjalanan.

Hasil penerapan algoritma GNN pada 5 POI menghasilkan urutan kunjungan dan total jarak seperti pada Tabel L 5.3.

Tabel L 5. 3 Urutan kunjungan hasil Greedy Nearest Neighbor

Urutan	Nama POI	Jarak dari sebelumnya (m)
1	Art: 1 New Museum	2503,43
2	Gedung Kesenian Jakarta	4441,72
3	National Monument (Monas)	1720,01
4	Textile Museum	2032,96
5	Taman Ismail Marzuki	3195,65



Gambar L 5. 1 Visualisasi Peta dengan Rute Teroptimasi (Garis Lurus)

Optimasi rute dengan algoritma Greedy Nearest Neighbor berhasil menyusun urutan kunjungan yang efisien dengan total jarak tempuh (dalam garis lurus) 13,89 km. Hasil ini menunjukkan bahwa algoritma mampu memberikan solusi mendekati optimal untuk permasalahan rute wisata dengan jumlah POI terbatas.